



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Escola Tècnica
Superior d'Enginyeria
Informàtica

Escuela Técnica Superior de Ingeniería Informática
Universidad Politécnica de Valencia

Clasificación automática de artrosis en rodillas mediante redes neuronales convolucionales

TRABAJO FIN DE GRADO

Grado en Ingeniería Informática

Autor: Hernández Martínez, Carlos

Tutor: Juan Ciscar, Alfonso

Curso 2024-2025

Resumen

Este Trabajo de Fin de Grado presenta el diseño, implementación y evaluación de un sistema de **clasificación automática de artrosis de rodilla** a partir de radiografías, empleando técnicas de *aprendizaje profundo*. Se aborda la problemática clínica de la **variabilidad interobservador** y la **subjetividad** inherentes al diagnóstico radiográfico tradicional, proponiendo modelos capaces de estandarizar y objetivar la estimación de severidad según la *escala Kellgren–Lawrence* (KL, 0–4).

Como base de datos principal se utiliza una versión curada del *Osteoarthritis Initiative* (OAI), con cerca de 9.800 imágenes de rodilla etiquetadas con KL, que presenta un notable **desbalance de clases**. Se adopta un **enfoque incremental**: (i) tres *CNN* diseñadas desde cero para establecer líneas base; (ii) **modelos preentrenados** mediante *transfer learning* (*EfficientNetB0* y *ResNet50*) con variantes de congelación y ajuste fino; y (iii) la evaluación de un *Transformer* de visión (*ViT-base patch16*) como alternativa no convolucional. Todos los modelos comparten un protocolo de entrenamiento unificado (optimizador Adam, *early stopping*, planificador de tasa de aprendizaje), **aumento de datos** (rotación, volteos, ajuste de brillo/contraste) y evaluación mediante *accuracy*, *F1-score* y *MAE*. Para **interpretabilidad**, se emplea *Grad-CAM* para verificar la atención sobre regiones anatómicas relevantes.

En OAI, las *CNN* profundas y, especialmente, las arquitecturas **preentrenadas** muestran una clara ventaja sobre los modelos desde cero. *EfficientNetB0* alcanza $\approx 68,6\%$ de *accuracy*, $\approx 64,8\%$ de *F1* y *MAE* $\approx 0,46$ en la versión regresiva; *ViT* obtiene resultados cercanos ($\approx 65,5\%$). En comparaciones binarias extremas (KL0 vs KL4), todas las arquitecturas superan el 99 %, confirmando que la dificultad radica en grados intermedios.

Como **validación externa**, se estudia la *transferencia interdominio* hacia un conjunto de 83 radiografías de rodilla felinas etiquetadas con KL. Se comparan tres regímenes: inferencia sin ajuste, entrenamiento directo y *fine-tuning* desde pesos entrenados en OAI. El *fine-tuning* logra la mejor generalización, alcanzando $\approx 80\%$ de *accuracy* (*ViT*) en clasificación binaria, mientras que la clasificación completa 0–4 sigue siendo un reto ($\approx 50\%$).

Este TFG **demuestra la viabilidad** de las *CNN* y *Transformers* como herramientas de apoyo al diagnóstico de la artrosis de rodilla, **valida el *transfer learning*** en contextos clínicos y **abre la puerta** a su uso en el ámbito veterinario. Persisten retos como el **desbalance de clases**, la **ambigüedad en grados leves**, el **tamaño reducido de muestras** y la **calibración** de modelos.

Palabras clave: artrosis de rodilla; redes neuronales convolucionales; aprendizaje profundo; aprendizaje por transferencia; Grad-CAM; diagnóstico asistido por ordenador; transferencia interdominio

Abstract

This Final Degree Project presents the design, implementation, and evaluation of a system for **automatic classification of knee osteoarthritis** from radiographs, using *deep learning* techniques. It addresses the clinical issue of **inter-observer variability** and **subjectivity** inherent in traditional radiographic diagnosis, proposing models capable of standardizing and objectifying severity estimation according to the *Kellgre-Lawrence* scale (KL, 0–4).

The main dataset used is a curated version of the *Osteoarthritis Initiative* (OAI), with approximately 9,800 knee images labeled with KL, presenting a notable **class imbalance**. An **incremental approach** was adopted: (i) three CNN architectures designed from scratch to establish baselines; (ii) **pretrained models** via *transfer learning* (*EfficientNetB0* and *ResNet50*) with variants of freezing and fine-tuning; and (iii) the evaluation of a vision *Transformer* (*ViT-base patch16*) as a non-convolutional alternative. All models follow a unified training protocol (Adam optimizer, *early stopping*, learning rate scheduler), **data augmentation** (rotation, flipping, brightness/contrast adjustment), and evaluation using *accuracy*, *F1-score*, and *MAE*. For **interpretability**, *Grad-CAM* was used to verify attention over relevant anatomical regions.

In OAI, deep CNNs and especially **pretrained** architectures show a clear advantage over models trained from scratch. *EfficientNetB0* reaches $\approx 68.6\%$ *accuracy*, $\approx 64.8\%$ *F1*, and *MAE* ≈ 0.46 in the regression version; *ViT* achieves similar results ($\approx 65.5\%$). In extreme binary comparisons (KL0 vs KL4), all architectures surpass 99%, confirming that the difficulty lies in intermediate grades.

As **external validation**, a *cross-domain transfer* study was conducted using a set of 83 feline knee radiographs labeled with KL. Three regimes were compared: inference without adjustment, full training, and *fine-tuning* from OAI-trained weights. *Fine-tuning* achieves the best generalization, reaching $\approx 80\%$ *accuracy* (ViT) in binary classification, while full 0–4 classification remains challenging ($\approx 50\%$).

This work **demonstrates the feasibility** of CNNs and *Transformers* as tools to support the diagnosis of knee osteoarthritis, **validates transfer learning** in clinical contexts, and **opens the door** to its application in the veterinary field. Challenges remain, such as **class imbalance**, **ambiguity in mild grades**, **small sample sizes**, and **model calibration**.

Key words: knee osteoarthritis; convolutional neural networks; deep learning; transfer learning; Grad-CAM; computer-aided diagnosis; cross-domain transfer

Resum

Este Treball de Fi de Grau presenta el disseny, implementació i avaluació d'un sistema de **classificació automàtica d'artrosi de genoll** a partir de radiografies, emprant tècniques d'*aprenentatge profund*. Aborda la problemàtica clínica de la **variabilitat interobservador** i la **subjectivitat** inherent al diagnòstic radiogràfic tradicional, proposant models capaços d'estandarditzar i objectivar l'estimació de la severitat segons l'*escala Kellgren-Lawrence* (KL, 0–4).

La base de dades principal és una versió curada de l'*Osteoarthritis Initiative* (OAI), amb prop de 9.800 imatges de genoll etiquetades amb KL, que presenta un destacat **desbalanceig de classes**. S'ha adoptat un **enfocament incremental**: (i) tres arquitectures CNN dissenyades des de zero per establir línies de base; (ii) **models preentrenats** mitjançant *transfer learning* (*EfficientNetB0* i *ResNet50*) amb variants de congelació i ajust fi; i (iii) l'avaluació d'un *Transformer* de visió (*ViT-base patch16*) com a alternativa no convolucional. Tots els models segueixen un protocol d'entrenament unificat (optimitzador Adam, *early stopping*, planificador de taxa d'aprenentatge), **augment de dades** (rotació, volteig, ajust de brillantor/contrast) i avaluació amb *accuracy*, *F1-score* i MAE. Per a la **interpretabilitat**, s'ha utilitzat *Grad-CAM* per verificar l'atenció sobre regions anatòmiques rellevants.

En OAI, les CNN profundes i, especialment, les arquitectures **preentrenades** mostren un clar avantatge respecte als models des de zero. *EfficientNetB0* aconsegueix $\approx 68,6\%$ *accuracy*, $\approx 64,8\%$ *F1* i MAE $\approx 0,46$ en la versió regressiva; *ViT* obté resultats similars ($\approx 65,5\%$). En comparacions binàries extremes (KL0 vs KL4), totes les arquitectures superen el 99%, confirmant que la dificultat es troba en graus intermedis.

Com a **validació externa**, s'ha realitzat un estudi de *transferència interdomanial* amb un conjunt de 83 radiografies de genoll felines etiquetades amb KL. S'han comparat tres règims: inferència sense ajust, entrenament complet i *fine-tuning* a partir de pesos entrenats en OAI. El *fine-tuning* aconsegueix la millor generalització, arribant a $\approx 80\%$ *accuracy* (*ViT*) en classificació binària, mentre que la classificació completa 0–4 continua sent un repte ($\approx 50\%$).

Aquest treball **demostra la viabilitat** de les CNN i *Transformers* com a eines de suport al diagnòstic de l'artrosi de genoll, **valida el *transfer learning*** en contextos clínics i **obre la porta** a la seua aplicació en l'àmbit veterinari. Persisteixen reptes com el **desbalanceig de classes**, l'**ambigüitat en graus lleus**, la **mida reduïda de mostres** i la **calibració dels models**.

Paraules clau: artrosi de genoll; xarxes neuronals convolucionals; aprenentatge profund; aprenentatge per transferència; Grad-CAM; diagnòstic assistit per ordinador; transferència interdomanial

Índice general

Índice general	VII
Índice de figuras	IX
Índice de tablas	IX
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos del TFG	2
2 Preliminares	5
2.1 Aprendizaje automático	5
2.2 Redes Neuronales	7
2.3 ML aplicado a VC y tareas biomédicas: caso MedMNIST	10
3 Dataset OAI y tareas comunes	13
3.1 Introducción	13
3.2 Dataset OAI	14
3.3 Dataset de gatos	16
3.4 Tareas comunes	17
3.5 Conclusiones	19
4 Redes Convolucionales	21
4.1 Introducción	21
4.2 Modelos	21
4.3 Experimentos	23
4.4 Conclusiones	26
5 Transformers	29
5.1 Introducción	29
5.2 Modelos	29
5.3 Experimentos	29
6 Fine-tuning para radiografías de gatos	31
6.1 Introducción	31
6.2 Selección de tareas y análisis de sentido clínico	31
6.3 Experimentos realizados	31
6.4 Resultados y análisis	31
6.5 Conclusiones	32
7 Conclusiones	35
7.1 Resumen del trabajo realizado	35
7.2 Objetivos alcanzados	35
7.3 Trabajo futuro	35
Apéndices	
A Configuración del sistema	39
B Otro apéndice	41

Índice de figuras

2.1	Ejemplo ilustrativo de subajuste, buen ajuste y sobreajuste en un modelo supervisado. Adaptado de [1].	5
2.2	Flujo de entrenamiento de un modelo supervisado mediante descenso de gradiente. Adaptado de [4].	6
2.3	Ejemplo de una red neuronal profunda [neural_network]	8
2.4	Ejemplo de arquitectura de una red neuronal convolucional para clasificación de imágenes. Se observan capas convolucionales (conv) que aplican filtros aprendibles sobre la imagen de entrada, seguidas de capas de pooling que reducen la resolución. Al final, capas totalmente conectadas (FC) procesan las características extraídas para producir la clasificación en alguna de las categorías.	9
3.1	Ejemplos de radiografías de rodilla clasificadas según la escala Kellgren & Lawrence (KL)	15
3.2	Distribución de clases (KL 0 a KL 4) en el conjunto de entrenamiento del dataset OAI. Se observa un desbalance significativo hacia los grados más leves.	16

Índice de tablas

3.1	Distribución de imágenes por partición	15
3.2	Distribución de clases en el conjunto de entrenamiento	15
3.3	Distribución de clases en el conjunto de entrenamiento	17
3.4	Comparativa de tareas y resultados en el dataset OAI	19
4.1	Resultados Simple CNN en clasificación y regresión	26
4.2	Resultados CNN mediana en clasificación y regresión	27
4.3	Resultados CNN grande en clasificación y regresión	27
4.4	Resultados EfficientNetB0 en clasificación y regresión	27
4.5	Resultados ResNet151 en clasificación y regresión	28
5.1	Resultados de google/vit-base-patch16-224	30
6.1	Resultados de la Tarea 0–4 para ViT y EfficientNetB0 con distintos tipos de entrenamiento	32
6.2	REGRESSION - Resultados de la Tarea 0–4 para ViT y EfficientNetB0 con distintos tipos de entrenamiento	32

6.3	Resultados de la Tarea 01vs234 para ViT y EfficientNetB0 con distintos tipos de entrenamiento	33
-----	---	----

CAPÍTULO 1

Introducción

La artrosis de rodilla es un problema de gran impacto clínico por su prevalencia y por la carga de discapacidad asociada. Su evaluación en radiografías sigue dependiendo, en gran medida, de la experiencia del profesional, lo que introduce variabilidad y dificulta la estandarización. En paralelo, el aprendizaje profundo ha demostrado capacidad para extraer patrones visuales sutiles y apoyar decisiones diagnósticas de forma consistente. Este TFG aborda la **clasificación automática del grado Kellgren–Lawrence (KL)** en radiografías de rodilla y estudia la **transferencia** de modelos entrenados en humanos hacia radiografías felinas, un contexto donde los datos son escasos. El trabajo se centra en *clasificación* sobre recortes ya localizados (no se aborda la detección de la articulación) y compara enfoques con *CNN* y *Transformers* bajo un protocolo unificado. A continuación se detallan la motivación, los objetivos y la metodología, y se describe la estructura de la memoria.

1.1 Motivación

Desde el inicio de mi formación académica he mostrado un especial interés por la aplicación de herramientas informáticas en el ámbito de la salud. Este interés se ha visto reforzado por mi entorno familiar, que me ha permitido estar en contacto con problemáticas relacionadas con el diagnóstico y tratamiento de enfermedades en animales. Además, la idea de este trabajo surgió a raíz de una compañera de trabajo de mi padre, quien tenía previsto realizar su tesis doctoral sobre la aplicación de IA en el diagnóstico veterinario. Este hecho me inspiró a explorar cómo las técnicas modernas de aprendizaje profundo, ampliamente utilizadas en medicina humana, podrían adaptarse también al ámbito veterinario.

Desde un principio tenía claro que el tema de mi Trabajo de Fin de Grado estaría relacionado con el aprendizaje automático. La oportunidad de vincularlo con el diagnóstico veterinario, pese a los retos añadidos por la limitación de datos disponibles, me llevó a elegir esta temática como base de mi investigación.

La artrosis (u osteoartritis) es una de las enfermedades musculoesqueléticas más comunes a nivel mundial y una de las principales causas de discapacidad en adultos mayores. Su diagnóstico y seguimiento dependen habitualmente de la evaluación clínica y de la interpretación de imágenes médicas (radiografías, resonancias magnéticas o tomografías), un proceso sujeto a la experiencia del profesional y que puede presentar variabilidad entre observadores. En los últimos años, los avances en IA, y en particular en el aprendizaje profundo (*deep learning*), han demostrado un gran potencial para mejorar la precisión y la eficiencia en el análisis de imágenes médicas. Las redes neuronales convolucionales (CNN) y, más recientemente, los modelos basados en *Transformers*, han

mostrado resultados prometedores en este ámbito, como evidencian recientes trabajos que emplean conjuntos de datos biomédicos como MedMNIST.

Este TFG se motiva por la necesidad de desarrollar métodos automáticos y robustos para el análisis de la artrosis mediante técnicas de aprendizaje profundo, evaluando tanto arquitecturas convolucionales como modelos *Transformer*. Un aspecto innovador de este trabajo es la exploración del *transfer learning* entre dominios anatómicos distintos, utilizando modelos entrenados en radiografías de rodillas humanas para aplicarlos también al diagnóstico en gatos. Esta línea de investigación podría beneficiar la práctica veterinaria, donde la disponibilidad de datos suele ser más limitada.

La relevancia de este estudio radica en su potencial impacto en la práctica clínica y veterinaria, al reducir la carga de trabajo de los especialistas, mejorar la objetividad del diagnóstico y ofrecer herramientas de soporte a la decisión clínica. Además, a nivel formativo, este proyecto me permite adquirir experiencia en técnicas avanzadas de visión por computador, gestión de conjuntos de datos biomédicos, entrenamiento de redes neuronales profundas y análisis de resultados, competencias clave para mi futuro profesional en el ámbito de la IA aplicada a la salud.

1.2 Objetivos del TFG

El propósito de este TFG es diseñar, implementar y validar un sistema de clasificación automática de artrosis de rodilla en radiografías, maximizando su utilidad clínica y su capacidad de generalización, incluso en contextos veterinarios con datos limitados. Para ello, se plantean los siguientes objetivos concretos y medibles:

1. **Desarrollar y comparar modelos de aprendizaje profundo** (CNN desde cero, modelos preentrenados y Transformers de visión) para la clasificación KL 0–4 y tareas binarias en OAI, *evaluando* su rendimiento bajo un protocolo unificado con *accuracy*, *macro-F1* y *MAE*, y *reportando*.
2. **Evaluar la transferencia interdominio humano→felino** comparando inferencia directa, entrenamiento desde cero y *fine-tuning* a partir de pesos en OAI, *cuantificando* diferencias de rendimiento entre los tipos de entrenamiento y los resultados utilizando el dataset OAI.

Estructura de la memoria

Este Trabajo Fin de Grado estudia la clasificación automática de artrosis de rodilla mediante aprendizaje profundo y su transferencia a radiografías felinas. La memoria se organiza del siguiente modo. En **Preliminares** se introducen los conceptos esenciales de aprendizaje automático y redes neuronales, así como su evolución reciente en visión por computador con ejemplos de conjuntos públicos biomédicos. El **Capítulo 3** describe los datos utilizados —el *dataset* OAI y el conjunto externo de radiografías felinas—, sus particiones y desbalance, y define las tareas de clasificación que se abordarán, situando el trabajo en su contexto. El **Capítulo 4** presenta los experimentos con *redes convolucionales*, incluyendo modelos desde cero y modelos preentrenados, bajo una configuración de entrenamiento unificada y con comparación de resultados. El **Capítulo 5** incorpora *Transformers* de visión, su adaptación a la tarea y su evaluación con el mismo protocolo. El **Capítulo 6** analiza la transferencia interdominio hacia radiografías felinas, comparando inferencia directa, entrenamiento específico y ajuste fino, y discutiendo su utilidad

clínica. En **Conclusiones** se sintetizan los hallazgos, se verifica el grado de cumplimiento de los objetivos y se proponen líneas futuras. La **Bibliografía** recoge las referencias empleadas. Los **Apéndices** incluyen la configuración del sistema (entorno, dependencias y parámetros de reproducción), tablas y métricas ampliadas y detalles de preprocesado. Dado que el tribunal puede ser interdisciplinar, al final se incorpora un **glosario de términos** técnicos para consulta.

CAPÍTULO 2

Preliminares

2.1 Aprendizaje automático

El **aprendizaje automático** (ML) es una rama de la inteligencia artificial que se enfoca en que las máquinas mejoren su desempeño en una tarea determinada a partir de la experiencia. Un sistema “*aprende*” cuando su desempeño en una tarea, medido por una métrica, mejora con la experiencia adquirida. En términos prácticos, esto implica diseñar algoritmos capaces de *generalizar* patrones a partir de datos, de forma que puedan hacer predicciones o tomar decisiones sobre datos no vistos previamente. En aprendizaje automático se suelen representar los datos con un conjunto de *características* (features) relevantes, y el algoritmo construye un modelo matemático que relaciona estas características con las salidas esperadas. Un objetivo central es lograr un buen equilibrio entre *ajuste* a los datos de entrenamiento y *capacidad de generalización* a nuevos datos, evitando problemas como el *sobreajuste* (overfitting). La Figura 2.1 ilustra de forma visual las diferencias entre subajuste, buen ajuste y sobreajuste en un modelo supervisado, conceptos fundamentales para entender el rendimiento de los modelos de aprendizaje automático.




Figura 2.1: Ejemplo ilustrativo de subajuste, buen ajuste y sobreajuste en un modelo supervisado. Adaptado de [1].

Existen varias categorías principales de aprendizaje automático, diferenciadas por la forma en que el algoritmo recibe la información y el tipo de tarea a resolver:

- **Aprendizaje supervisado:** El algoritmo recibe ejemplos de entrada y su correspondiente salida deseada (etiquetas). El objetivo es aprender una función que mapee las entradas a las salidas correctas. Son tareas típicas la *clasificación* (p. ej., dado un conjunto de características de un paciente, predecir que enfermedad tiene: salida categórica) y la *regresión* (p. ej., dada las características de una casa predecir su precio). El rendimiento se evalúa comúnmente con funciones que relacionan la predicción del modelo con el valor real (p. ej. error cuadrático en regresión o entropía cruzada en clasificación).

- **Aprendizaje no supervisado:** El algoritmo recibe datos de entrada sin etiquetas, y debe descubrir estructura oculta en ellos. Incluye tareas como la *clustering* (agrupamiento de datos por similitud) o la *reducción de dimensionalidad* (encontrar representaciones más compactas de los datos). Un claro ejemplo de aprendizaje no supervisado consiste en la agrupación de correos en distintos tipos.
- **Aprendizaje por refuerzo:** El algoritmo (un *agente*) aprende a través de la interacción con un entorno, recibiendo recompensas o penalizaciones según sus acciones. El agente debe descubrir una política de acciones que maximice la recompensa acumulada. Este paradigma es común en robótica y juegos, donde no se proporcionan ejemplos de solución directa sino una señal de calidad de cada acción.

En el ámbito médico se utiliza comunmente el **aprendizaje supervisado**. El proceso típico de esta tarea consiste en entrenar un modelo ajustando sus parámetros para minimizar una función de error o *función de pérdida* (loss function) que mide el error de las predicciones del modelo sobre los datos de entrenamiento. El procedimiento de optimización más utilizado es el *descenso de gradiente* y sus variantes, como el descenso de gradiente estocástico, que permite procesar los datos por lotes. En cada iteración, se calcula la gradiente del error respecto a los parámetros del modelo, y se ajustan los parámetros en la dirección opuesta a dicha gradiente para reducir el error. Este ciclo se repite múltiples veces (*épocas*) hasta converger a un mínimo local del error.

La Figura 2.2 muestra esquemáticamente el flujo de este proceso, donde la posición inicial tiene el error máximo y en cada iteración se va reduciendo el error (como una pelota que rueda por una pendiente). A continuación, el Algoritmo 2.1 detalla los pasos fundamentales que se siguen durante el entrenamiento de un modelo mediante esta técnica.




Figura 2.2: Flujo de entrenamiento de un modelo supervisado mediante descenso de gradiente. Adaptado de [4].

Require: Conjunto de entrenamiento $(x_i, y_i)_{i=1}^N$, tasa de aprendizaje η función de error $\mathcal{L}$

```

Inicializar parámetros del modelo  $\theta$  (p. ej. aleatoriamente)
for numero de épocas do
  for cada  $(x_i, y_i)$  en  $(x_i, y_i)_{i=1}^N$  do

```

```

    calcular predicción  $\hat{y}_i = f_{\theta}(x_i)$ 
    calcular pérdida  $L = \mathcal{L}(\hat{y}_i, y_i)$  {ej.: error cuadrático, entropía cruzada, etc.}
    calcular gradiente  $g = \nabla_{\theta} L$ 
    actualizar parámetros:  $\theta := \theta - \eta \cdot g$ 
  end for
end for

```

Tras el entrenamiento, es fundamental evaluar el modelo con datos independientes (conjunto de *prueba*) para estimar su capacidad de generalización. Además, suelen emplearse técnicas como *validación cruzada* y conjuntos de *validación* para ajustar hiperparámetros (parámetros del algoritmo que no se aprenden directamente, como la profundidad de un árbol de decisión o la tasa de aprendizaje η). Un buen enfoque de validación ayuda a prevenir el sobreajuste y a seleccionar modelos más robustos.

Existen algoritmos clásicos de ML como los *árboles de decisión*, *máquinas de vector soporte* (SVM), *vecinos más cercanos* (k-NN), entre otros, cada uno con sus supuestos y ámbitos de aplicación. Por ejemplo, las SVM buscan hiperplanos que separen clases maximizando el margen, mientras que los árboles de decisión realizan particiones recursivas del espacio de características para homogeneizar las etiquetas en los nodos hoja. La elección del algoritmo adecuado depende de la naturaleza de los datos y del problema a resolver, no existiendo un modelo único que sea óptimo para todas las tareas.

En resumen, el aprendizaje automático proporciona las bases para construir modelos que extraen conocimiento de los datos. Estos conceptos preliminares resultan imprescindibles para entender técnicas más avanzadas como las redes neuronales profundas y su aplicación en tareas de visión por computador y medicina, que se abordan en secciones posteriores.

2.2 Redes Neuronales

Las **redes neuronales artificiales** (RNA) constituyen una familia de modelos de aprendizaje automático inspirados vagamente en el cerebro humano. La unidad básica de una RNA es la *neurona artificial*, un elemento que realiza una operación sencilla: calcula una combinación lineal de sus entradas y le aplica una función no lineal llamada *función de activación*. Matemáticamente, si una neurona recibe como entradas $x_1, x_2, \dots, x_n$ con pesos sinápticos $w_1, w_2, \dots, w_n$ y tiene un sesgo b , produce una salida $y = \sigma(w_1x_1 + w_2x_2 + \dots + w_nx_n + b)$, donde $\sigma(\cdot)$ podría ser, por ejemplo, una función sigmoide, tangente hiperbólica o ReLU (Unidad Lineal Rectificada). Las primeras RNA, como el *Perceptrón* de Rosenblatt, tenían una sola capa de neuronas (una capa de entrada proyectada directamente a una capa de salida) y podían aprender a clasificar datos que fueran linealmente separables. Sin embargo, se demostró que una sola neurona (o capa lineal) tiene limitaciones significativas en su capacidad de representación.

La potencia de las redes neuronales radica en su capacidad para formar **arquitecturas multicapa**, también conocidas como *redes neuronales de múltiples capas* o *perceptrones multicapa* (MLP). Estas redes están organizadas en capas: una capa de entrada (los datos originales), una o varias capas *ocultas* que realizan transformaciones intermedias mediante neuronas con sus pesos, y una capa de salida que produce la predicción final. Al agregar capas ocultas con funciones de activación no lineales, las redes adquieren la habilidad de aproximar relaciones no lineales arbitrariamente complejas entre la entrada y la salida. En la imagen 2.3 se observa un ejemplo de una red neuronal profunda, donde cada círculo representa una neurona y las líneas indican las conexiones entre ellas.




Figura 2.3: Ejemplo de una red neuronal profunda [neural_network]

El entrenamiento de una red neuronal multicapa se realiza típicamente mediante el algoritmo de *retropropagación del error* (backpropagation) combinado con descenso de gradiente. En esencia, el procedimiento es: se calculan las salidas de la red para una entrada dada (*fase forward*), se mide el error cometido comparando con la salida deseada mediante una función de coste (por ejemplo, la entropía cruzada para clasificación), y luego se propaga ese error hacia atrás a través de la red (*fase backward*) calculando las derivadas parciales del error con respecto a cada peso utilizando la regla de la cadena. Estas derivadas indican cómo ajustar cada peso para reducir el error, y se aplican las actualizaciones de los pesos en consecuencia. Gracias a la retropropagación, las redes neuronales pueden entrenarse eficientemente incluso con muchas capas, ajustando millones de parámetros para adaptarse a complejos conjuntos de datos. Este avance fue crucial para el renacimiento de las redes neuronales en la década de 1980, tras un período de estancamiento parcial debido a las limitaciones de los perceptrones simples destacadas por Minsky y Papert en 1969 (quienes señalaron, por ejemplo, que un perceptrón no podía aprender la función XOR). El trabajo de Rumelhart, Hinton y Williams (1986) introdujo formalmente la retropropagación, mostrando que las redes de múltiples capas podían aprender características jerárquicas y superar esas limitaciones previas.

A medida que se dispuso de más datos y mayor potencia de cómputo, especialmente con la llegada de unidades de procesamiento gráfico (GPU) que aceleraron el cálculo matricial masivo, las redes neuronales crecieron en profundidad y capacidad. Surge así el campo del **aprendizaje profundo** (*deep learning*), que no es más que el uso de redes neuronales con muchas capas (a veces decenas o incluso cientos) entrenadas sobre grandes volúmenes de datos. Un hito simbólico fue la competición ImageNet de 2012, en la cual una red convolucional profunda llamada *AlexNet* obtuvo un rendimiento muy superior al de los métodos tradicionales en la tarea de clasificación de imágenes a gran escala. *AlexNet*, desarrollada por Krizhevsky et al. (2012), tenía 8 capas entrenables y introdujo técnicas como capas de *dropout* para regularización y entrenamiento en GPU, marcando el inicio de una nueva era en visión por computador impulsada por redes neuronales profundas. Desde entonces, arquitecturas aún más profundas y sofisticadas han emergido, como *VGGNet* (2014, 16-19 capas), *Inception/GoogLeNet* (2015, con módulos de convolución en paralelo) y *ResNet* (2016, más de 50 capas). En particular, las **redes residuales** (ResNets) de He et al. (2016) introdujeron conexiones de atajo (skip connections) que mitigaron el problema de la degradación del gradiente en redes muy profundas, permitiendo entrenar exitosamente redes de incluso 152 capas con mejoras significativas en la precisión de tareas de visión.

Una clase especial y sumamente importante de RNA para datos con estructura espacial o temporal son las **redes neuronales convolucionales** (CNN, por sus siglas en inglés). Las CNN fueron concebidas originalmente para procesar imágenes, inspiradas en la organización del córtex visual animal. En una CNN, en lugar de conectar todas las

neuronas de una capa a todas las de la siguiente (como en un MLP denso tradicional), se emplean *capas convolucionales* donde cada neurona está conectada solo a una región local de la capa anterior (campo receptivo) y todas las neuronas de una capa comparten conjuntos de pesos (filtros) que se *desplazan* sobre la entrada. Esta estructura explota las propiedades de *estacionariedad* de las imágenes (patrones locales similares pueden aparecer en cualquier ubicación) y reduce drásticamente el número de parámetros al introducir *pesos compartidos*. Además, se intercalan típicamente *capas de pooling* (submuestreo), que reducen la resolución espacial agrupando activaciones cercanas (por ejemplo, tomando el máximo de cada bloque 2×2 de neuronas), confiriendo invarianza a traslaciones pequeñas y reduciendo la dimensionalidad progresivamente. Una arquitectura CNN típica para clasificación de imágenes consiste en varias capas convolucionales+pooling en cascada, que extraen características cada vez más abstractas de la imagen (bordes, texturas, partes, objetos), seguidas de una o más capas totalmente conectadas que actúan como clasificador final sobre esas características extraídas. La Figura 2.4 muestra esquemáticamente un ejemplo de arquitectura CNN simple, con sus etapas de convolución, pooling y capas densas finales.




Figura 2.4: Ejemplo de arquitectura de una red neuronal convolucional para clasificación de imágenes. Se observan capas convolucionales (conv) que aplican filtros aprendibles sobre la imagen de entrada, seguidas de capas de pooling que reducen la resolución. Al final, capas totalmente conectadas (FC) procesan las características extraídas para producir la clasificación en alguna de las categorías.

Las CNN han demostrado ser extremadamente efectivas en visión por computador, logrando reconocer objetos en fotos con gran precisión, segmentar imágenes píxel a píxel, detectar rostros, entre muchas otras aplicaciones. En el ámbito de imágenes médicas, han superado enfoques tradicionales al detectar patrones sutiles en radiografías, resonancias o microscopías que serían difíciles de modelar manualmente. No obstante, entrenar redes profundas con éxito requiere una gran cantidad de datos clasificados de manera manual, siendo de mayor dificultad en el ámbito médico donde la anotación de imágenes es costosa y requiere experiencia especializada. Cuando el conjunto de datos disponible es limitado, es frecuente recurrir a *aprendizaje por transferencia*, utilizando redes pre-entrenadas en un dominio amplio (p. ej., ImageNet) y refinándolas (fine-tuning) sobre la tarea específica, aprovechando características visuales genéricas aprendidas previamente.

Otro aspecto relevante es la *interpretabilidad* de las predicciones de las redes neuronales. Las RNA profundas han sido criticadas como “cajas negras” difíciles de entender; sin embargo, se han desarrollado técnicas para visualizar y explicar qué han aprendido. Por ejemplo, en imágenes, métodos como *Grad-CAM* (Gradiente-Weighted Class Activation Mapping) permiten resaltar las regiones de la imagen que más contribuyen a una determinada predicción de la red, proporcionando pistas sobre qué está “mirando” la CNN al

tomar su decisión, pudiendo determinar si la red se basa en características relevantes o si ha aprendido patrones no generalizables (p. ej. clasificando imágenes por el fondo en lugar del objeto de interés).

En suma, las redes neuronales (especialmente las convolucionales profundas) constituyen la columna vertebral de muchos sistemas modernos de inteligencia artificial, logrando avances sin precedentes en reconocimiento de patrones. En la siguiente sección se explorará cómo estas técnicas de ML y redes neuronales se aplican en el ámbito de la visión por computador biomédica, con énfasis en el caso MedMNIST y la clasificación de artrosis en rodillas.

2.3 ML aplicado a VC y tareas biomédicas: caso MedMNIST

La integración de técnicas de aprendizaje profundo y visión por computadora ha revolucionado el análisis de imágenes biomédicas en la última década. Tradicionalmente, la interpretación de imágenes médicas como radiografías, resonancias magnéticas y microscopías dependía exclusivamente de la habilidad humana. Sin embargo, en la actualidad, los algoritmos de *deep learning* han igualado e incluso superado el desempeño de especialistas en diversas tareas diagnósticas.

Un ejemplo destacado es la empresa Quibim, fundada por el exalumno de la UPV, Ángel Alberich-Bayarri. Quibim ha desarrollado modelos basados en inteligencia artificial para la detección del cáncer de próstata en resonancias magnéticas. Su herramienta, QP-Prostate®, utiliza algoritmos avanzados para identificar y clasificar lesiones sospechosas en la glándula prostática, mejorando la precisión diagnóstica y facilitando la planificación de biopsias dirigidas.

Además, se han entrenado redes neuronales convolucionales para detectar retinopatía diabética en fotografías de retina, cáncer de piel en imágenes dermatoscópicas y neumonía en radiografías de tórax, alcanzando niveles de sensibilidad y especificidad comparables a los de médicos especialistas. Un metaanálisis realizado por Liu et al. (2019) concluyó que los clasificadores basados en aprendizaje profundo presentan, en promedio, un desempeño similar al de profesionales de la salud en la detección de enfermedades a partir de imágenes médicas, resaltando el potencial de estas técnicas para apoyar la labor clínica.

En el caso particular de la **artrosis de rodilla** (u osteoartritis), la radiografía es la técnica más utilizada para evaluar la gravedad de la enfermedad. Los radiólogos emplean un criterio estandarizado, la *escala Kellgren-Lawrence (KL)*, que asigna un grado de 0 a 4 a la rodilla en función de signos radiográficos de degeneración (osteofitos, estrechamiento del espacio articular, esclerosis, deformidad). Sin embargo, la lectura de estas radiografías puede ser subjetiva y presentar variabilidad entre observadores. Por ello, existe un gran interés en desarrollar sistemas automáticos que clasifiquen el grado KL a partir de la imagen de rayos X de la rodilla de forma consistente y reproducible.

Dado el amplio espectro de modalidades y problemas en imágenes médicas, han surgido iniciativas para facilitar la investigación y comparación de algoritmos en múltiples tareas. Un ejemplo es la **Osteoarthritis Initiative (OAI)**, que ha desarrollado un conjunto de datos de radiografías de rodilla con anotaciones de grado Kellgren-Lawrence (KL) el cual se desarrollará mas adelante. Otro caso notable es **MedMNIST**, una colección de conjuntos de datos biomédicos de pequeño tamaño inspirada en el famoso MNIST (conjunto de datos de dígitos escritos a mano) pero orientada a imágenes médicas. En su versión más reciente, *MedMNIST v2*, recopila 12 conjuntos de datos 2D (imágenes estáticas de 28×28 píxeles) y 6 conjuntos 3D (volúmenes de $28 \times 28 \times 28$ vóxeles), abarcando

diversas modalidades y tareas de clasificación biomédica. Por ejemplo, incluye láminas histológicas coloreadas (*PathMNIST*, 9 clases de tejidos patológicos), imágenes dermatoscópicas de lunares (*DermaMNIST*, clasificación de lesiones cutáneas) y radiografías de tórax (*ChestMNIST*, etiquetas multilabel de hallazgos torácicos), hasta estudios de retina OCT (*OCTMNIST*, detección de patologías retinales), entre otros. Cada subconjunto viene preprocesado y separado en particiones de entrenamiento, validación y prueba estandarizadas, lo que facilita la aplicación directa de algoritmos y la comparación justa entre ellos.

MedMNIST fue diseñado con varios objetivos clave en mente:

- **Diversidad:** Cubre múltiples modalidades de imagen (radiografías, tomografías, resonancias, ecografías, imágenes microscopias, etc.), distintos tamaños de datos (desde ~ 100 hasta $> 100,000$ imágenes) y tareas de clasificación variadas (binaria, multiclase, multietiqueta e incluso regresión ordinal). Esto permite evaluar la generalización de los algoritmos de aprendizaje automático en distintos escenarios con un solo recurso unificado.
- **Estandarización:** Todos los conjuntos están uniformizados a la misma resolución (imágenes pequeñas de 28×28 píxeles para 2D, o cubos de 28^3 para 3D) con formato de datos consistente. Asimismo, se proveen divisiones oficiales en entrenamiento/validación/test para cada dataset. Gracias a esto, los investigadores pueden centrarse en diseñar y probar modelos de *machine learning* sin preocuparse por el preprocesamiento de datos o posibles sesgos en la separación de conjuntos, y los resultados son comparables entre diferentes estudios de forma más directa.
- **Ligereza y accesibilidad:** El reducido tamaño de las imágenes hace que ejecutar experimentos sea computacionalmente liviano, incluso sin hardware especializado. Además, la colección es de libre acceso con licencia abierta (CC BY) y cuenta con una API unificada (disponible vía `pip install medmnist`) para cargar los datos fácilmente en diversos lenguajes. Esto democratiza la experimentación en análisis de imágenes médicas, permitiendo a estudiantes y grupos con recursos limitados explorar algoritmos de clasificación sobre datos reales de medicina.
- **Benchmark:** MedMNIST sirve tanto para introducir a nuevos usuarios en el campo de la visión médica, al proporcionar casos ya preparados sobre los cuales practicar, como para benchmarking de algoritmos de AutoML y redes neuronales en múltiples tareas livianas. Al enfocarse en imágenes pequeñas, enfatiza más el aspecto algorítmico (diseño del modelo, estrategias de aprendizaje) que el meramente computacional. De hecho, trabajos asociados han evaluado métodos clásicos de deep learning (ResNet, DenseNet, etc.) y herramientas AutoML sobre MedMNIST, generando un punto de referencia inicial de desempeños.

En resumen, iniciativas como MedMNIST complementan a los grandes desafíos clínicos (ej. clasificar artrosis en radiografías completas) ofreciendo un “laboratorio” controlado para probar métodos de aprendizaje automático en imágenes biomédicas. El presente proyecto de TFG se enmarca precisamente en este contexto: la aplicación del aprendizaje automático a la clasificación de artrosis de rodilla, un problema relevante en el campo de la salud musculoesquelética. Aprovechando conjuntos de datos como el de OAI [2] (con imágenes reales de pacientes) y los avances reportados en la literatura, se buscará entrenar un modelo capaz de predecir el estado de la articulación a partir de la radiografía, evaluando su desempeño y utilizando técnicas de interpretación como *Grad-CAM*. De este modo, se pretende contribuir tanto a la validación de las técnicas de aprendizaje profundo en una tarea biomédica específica como a la comprensión de sus alcances y limitaciones en un entorno clínico real.

Dataset OAI y tareas comunes

3.1 Introducción

La correcta selección y descripción de los conjuntos de datos es fundamental para el desarrollo riguroso de cualquier proyecto de visión por ordenador. En este capítulo, presentamos en detalle los dos recursos principales que sustentan este Trabajo de Fin de Grado: el *dataset* OAI y el *dataset* de gatos. Ambos provienen de contextos y dominios distintos —medicina radiológica y clasificación zoológica—, lo que nos permite ilustrar la aplicabilidad de las técnicas de aprendizaje profundo en entornos diversos y evaluar la robustez de los modelos propuestos.

El *dataset* OAI (*Osteoarthritis Initiative*) constituye un estudio observacional multicéntrico de más de una década de duración, diseñado para captar la progresión de la artrosis de rodilla mediante imágenes radiográficas y datos clínicos asociados. Su riqueza en términos de metadatos clínicos, visitas longitudinales y variedad de modalidades de imagen lo convierte en un estándar de referencia en la literatura científica sobre artrosis. La explotación de este recurso permite abordar tareas de diagnóstico automatizado, pronóstico de la enfermedad y evaluación de biomarcadores, ámbitos que requieren una descripción exhaustiva de las características de adquisición, las etiquetas disponibles y los posibles sesgos inherentes al diseño del estudio.

Por su parte, el *dataset* de gatos representa un ejemplo de conjunto de datos de clasificación de imágenes en un dominio completamente distinto. Aunque de menor escala, este conjunto aporta diversidad de condiciones de iluminación, posturas y categorías diagnósticas, lo que lo hace idóneo para evaluar la generalización de modelos entrenados en contextos médicos a tareas de clasificación más convencionales. Su inclusión en este trabajo busca comparar cómo técnicas similares de procesamiento y clasificación responden a datasets con distribuciones y tamaños muy dispares.

Para la anotación de las imágenes radiográficas de rodilla, la escala de severidad convencional es la **Kellgren-Lawrence (KL)**, un sistema ordinal que clasifica la artrosis en cinco grados:

- **Grado 0:** Ausencia de signos radiográficos de artrosis.
- **Grado 1:** Dudoso; posible pinzamiento mínimo del espacio articular o formación muy incipiente de osteofitos marginales.
- **Grado 2:** Leve; presencia clara de osteofitos y estrechamiento leve del espacio articular.

- **Grado 3:** Moderado; múltiples osteofitos de tamaño medio, pinzamiento definido del espacio articular y esclerosis subcondral leve.
- **Grado 4:** Severo; grandes osteofitos, estrechamiento marcado del espacio articular, esclerosis subcondral significativa y deformidad ósea evidente.

Este enfoque ordinal de graduación sirve de modelo conceptual para definir categorías en ambos conjuntos de datos, facilitando la comparación y el diseño de tareas de clasificación tanto en imágenes médicas como en imágenes de gatos.

La sección 3.2 describirá con detalle la estructura, particiones y características del *dataset* OAI, enfatizando sus splits, resolución de imágenes y distribuciones de clases. Acto seguido, en la sección 3.3 se presentará el *dataset* de gatos, incluyendo su origen, tiquetas, número de muestras y proporciones de entrenamiento y validación (70/30). En la sección ?? se revisarán las tareas de clasificación binaria, multiclase y formulaciones ordinales o de regresión— que se aplican a ambos datasets, junto con consideraciones sobre desbalance de clases, técnicas de preprocesamiento y métricas de evaluación. Finalmente, la sección 3.5 sintetizará las principales observaciones y sentará las bases metodológicas para los capítulos posteriores.

Con esta estructura, se busca proporcionar una visión integral de los recursos de datos y de las tareas de clasificación, facilitando la comprensión y reproducibilidad de los experimentos realizados.

3.2 Dataset OAI

El *Osteoarthritis Initiative (OAI)* es un estudio observacional, multicéntrico y longitudinal lanzado en 2004 por los NIH de EE.UU., cuyo objetivo principal ha sido identificar y validar biomarcadores asociados tanto a la incidencia como a la progresión de la artrosis de rodilla sintomática. Gracias a su diseño de más de diez años de seguimiento, este recurso se ha consolidado como un estándar en la investigación sobre artrosis, proporcionando no solo imágenes radiográficas, sino también metadatos clínicos, demográficos y de biospecímenes. Aunque solo se utilizarán las imágenes radiográficas de rodilla, es importante destacar que el OAI incluye un amplio espectro de datos,

Para facilitar su uso en tareas de aprendizaje automático, se emplea una versión curada de la OAI disponible en Mendeley Data y Kaggle. Este recurso procesado consta de 9786 radiografías de rodilla recortadas y preprocesadas, con etiquetas de severidad basadas en la escala Kellgren-Lawrence (KL) de 0 a 4, asignadas por radiólogos expertos. Los usuarios pueden descargar dos resoluciones estándar (224x224 y 299x299 píxeles) en Mendeley Data, mientras que en Kaggle solo se ofrece la versión de 224x224 píxeles, optimizada para arquitecturas CNN como ResNet, VGG, EfficientNet e Inception.

La Figura 3.1 muestra ejemplos visuales de radiografías correspondientes a cada uno de los grados KL. A pesar de su amplio uso, la escala KL presenta limitaciones conocidas, como su subjetividad y variabilidad interobservador, lo que motiva la búsqueda de métodos automáticos y objetivos para la evaluación de la OA [3].

El dataset publicado en Mendeley Data por Chen, estrechamente vinculado a su trabajo posterior sobre clasificación automática de grados KL mediante redes neuronales profundas [3], es un ejemplo prominente y fue específicamente organizado para facilitar tareas de detección de la articulación y clasificación de la severidad. Las características generales de estas versiones procesadas, que constituyen la base de numerosos estudios posteriores (incluido el presente trabajo), suelen ser las siguientes:




Figura 3.1: Ejemplos de radiografías de rodilla clasificadas según la escala Kellgren & Lawrence (KL)

- **Imágenes:** El conjunto total incluye **9 786 imágenes**, distribuidas en cuatro particiones diferenciadas: *train* (5 778), *validation* (826), *test* (1 656) y *auto_test* (1 526), como se muestra en la Tabla 3.1.

Tabla 3.1: Distribución de imágenes por partición

Partición	Número de imágenes	Porcentaje
Entrenamiento (Train)	5 778	59.0 %
Validación (Validation)	826	8.4 %
Prueba (Test)	1 656	16.9 %
Autoevaluación (AutoTest)	1 526	15.6 %

- **Etiquetas:** Cada imagen está etiquetada con un grado KL (de 0 a 4), siguiendo el criterio de radiólogos expertos de la OAI. Esta información es clave para entrenar modelos supervisados de clasificación.
- **Resolución y preprocesamiento:** En la versión de Mendeley, las imágenes se encuentran disponibles en dos resoluciones estándar: **224x224** y **299x299** píxeles, facilitando el uso de arquitecturas preentrenadas como ResNet o EfficientNet. En la versión de Kaggle solo están disponibles en 224x224 píxeles, lo que la hace más directa para su uso en modelos CNN comunes.
- **Distribución de clases:** La Tabla 3.2 muestra la distribución de clases en el conjunto de entrenamiento. Se observa un claro desbalance hacia las clases más leves de artrosis, lo que debe considerarse en el diseño de los modelos de clasificación.

Tabla 3.2: Distribución de clases en el conjunto de entrenamiento

Clase KL	Índice	Imágenes	Porcentaje
0 (Sin artrosis)	0	2 286	40 %
1 (Ligera)	1	1 046	18 %
2 (Leve)	2	1 516	26 %
3 (Moderada)	3	757	13 %
4 (Severa)	4	173	3 %

Como se observa, el conjunto de entrenamiento presenta un notable desbalance de clases, con predominancia de imágenes etiquetadas con grado 0 (sin artrosis) y grado 2 (leve), y una clara escasez de imágenes con grado 4 (severa). Este desbalance puede inducir a que el modelo favorezca las clases más frecuentes durante el entrenamiento, afectando negativamente su capacidad para detectar los casos más críticos.




Figura 3.2: Distribución de clases (KL 0 a KL 4) en el conjunto de entrenamiento del dataset OAI. Se observa un desbalance significativo hacia los grados más leves.

- Divisiones (Splits):** La existencia de splits predefinidos facilita la reproducibilidad de experimentos y la comparación entre distintos enfoques. Considerando únicamente los subconjuntos *train*, *validation* y *test* —que son los habitualmente utilizados para entrenar y evaluar modelos— se mantiene una proporción aproximada de **70 % entrenamiento**, **10 % validación** y **20 % test**, ampliamente adoptada en la comunidad. El conjunto *auto_test*, aunque no se utiliza en todos los trabajos, está disponible como recurso adicional que se utiliza en ocasiones para aumentar la cantidad de imágenes en el entrenamiento.

3.3 Dataset de gatos

El *dataset* de gatos es un conjunto de imágenes privadas recopiladas en el marco del Trabajo de Fin de Grado de Bea. Aunque de escala reducida en comparación con el OAI, aporta un caso de estudio valioso para evaluar la generalización de modelos de clasificación entrenados en un dominio tan distinto.

Este conjunto de datos fue obtenido por Bea mediante fotografía controlada de ejemplares felinos, cubriendo diversas posturas y condiciones de iluminación. Las imágenes no están disponibles públicamente y su uso queda restringido a fines de investigación, bajo autorización expresa de la autora.

El conjunto incluye radiografías de rodillas de gato tanto en vista frontal como lateral, todas ellas anotadas según la escala Kellgren-Lawrence (KL). Para mantener la coherencia anatómica y metodológica con el dataset OAI, en este trabajo se utilizarán únicamente las proyecciones frontales.

En total se dispone de 83 radiografías de gatos, distribuidas en 5 clases según la severidad de la artrosis. La Tabla 3.3 muestra la distribución de clases de todo el dataset.

Este conjunto de imágenes felinas funcionará como un conjunto de validación externo durante el proceso de entrenamiento de los modelos basados en el dataset OAI. Su propósito es poner a prueba la capacidad de generalización de los clasificadores aprendidos sobre radiografías humanas, aplicándolos a un dominio anatómico distinto pero con la misma tarea de gradación de artrosis. Al enfrentar los modelos a variaciones en la mor-

Tabla 3.3: Distribución de clases en el conjunto de entrenamiento

Clase KL	Imágenes	Porcentaje
0 (Sin artrosis)	30	36,6 %
1 (Ligera)	21	25,6 %
2 (Leve)	18	22,0 %
3 (Moderada)	11	13,4 %
4 (Severa)	2	2,4 %

fología articular y en las condiciones de adquisición, podremos cuantificar de manera objetiva su robustez frente a cambios de dominio.

El ajuste fino (fine-tuning) se llevará a cabo siguiendo dos vertientes complementarias. En la primera, partiremos de arquitecturas preentrenadas en grandes repositorios genéricos (por ejemplo, ImageNet), tal como se realizó en los experimentos con el dataset OAI. En la segunda, utilizaremos directamente los modelos preentrenados sobre el propio dataset OAI, aprovechando sus pesos como punto de partida para un nuevo entrenamiento dirigido al dominio de gatos. En ambas estrategias se adoptará un enfoque conservador: las capas iniciales del backbone permanecerán congeladas, afinándose únicamente las capas superiores y la cabeza de clasificación. De esta forma, se minimiza el riesgo de sobreajuste y se maximiza la transferencia de características útiles a pesar del tamaño reducido del dataset de gatos.

3.4 Tareas comunes

El conjunto de datos de la *Osteoarthritis Initiative* (OAI) ha sido ampliamente empleado en la literatura científica como base para el desarrollo de modelos de aprendizaje profundo orientados al diagnóstico automatizado de la artrosis de rodilla. Gracias a su riqueza clínica y su volumen de imágenes radiográficas etiquetadas según la escala de Kellgren-Lawrence (KL), este dataset se ha convertido en una referencia para la validación de nuevas arquitecturas y metodologías dentro del ámbito de la inteligencia artificial aplicada a la medicina.

A lo largo del tiempo, diferentes líneas de investigación han coincidido en una serie de tareas recurrentes que abordan distintos enfoques sobre la severidad de la artrosis. Estas tareas pueden clasificarse, principalmente, en función de tres criterios:

- El tipo de clasificación: binaria (presencia o ausencia de artrosis) o multiclase (grados de KL de 0 a 4).
- La metodología de entrenamiento: desde cero (*from scratch*) o mediante *transfer learning* con redes preentrenadas.
- La formulación del problema: como clasificación ordinaria o regresión ordinal.

Cabe destacar que estas tareas no son excluyentes, y muchas publicaciones recientes exploran combinaciones de estos enfoques. Además, se ha popularizado el uso de técnicas complementarias como el ensamblado de modelos (ensembling), el ajuste fino de pesos (fine-tuning) o el uso de funciones de pérdida adaptadas a la naturaleza ordinal del problema.

En el contexto de este Trabajo de Fin de Grado, el foco se centrará exclusivamente en la tarea de clasificación del grado de artrosis, descartando explícitamente la tarea de

detección automática de la articulación de la rodilla. Se parte de imágenes radiográficas previamente recortadas como se encuentran en los datasets disponibles en Mendeley y Kaggle, donde la articulación ya ha sido detectada y centrada, pudiendo replicar los experimentos de otros autores y comparar los resultados obtenidos de una manera más directa.

A modo de ejemplo representativo de las tareas descritas, se presentan a continuación varios estudios recientes que han abordado el problema de clasificación de la artrosis de rodilla utilizando el dataset OAI, cada uno desde una perspectiva metodológica distinta. Estos trabajos ilustran bien la diversidad de aproximaciones y motivaciones que existen en la literatura científica actual, y permiten contextualizar el enfoque adoptado en este Trabajo de Fin de Grado.

Chen et al. (2019) [3] desarrollan un sistema completamente automatizado para la clasificación de la severidad de la artrosis de rodilla, combinando detección de la articulación con YOLOv2 y posterior clasificación mediante redes neuronales profundas. En el contexto de este TFG, el interés se centra en la segunda fase del pipeline: la predicción del grado de artrosis según la escala de Kellgren-Lawrence (KL). Los autores emplean arquitecturas CNN preentrenadas como VGG, ResNet, InceptionV3 y DenseNet, afinadas con una función de pérdida personalizada denominada adjustable ordinal loss, diseñada para penalizar más severamente los errores a mayor distancia ordinal. Los resultados muestran que esta función mejora el rendimiento frente a la entropía cruzada tradicional, alcanzando una precisión del 70.4 % con VGG-19 como mejor modelo. Esta propuesta es destacable por introducir de manera explícita la naturaleza ordinal de las etiquetas KL en el proceso de entrenamiento, aspecto esencial para tareas clínicas con niveles de severidad escalonados.

Rafique et al. (2024) [rafique2024knee] proponen un enfoque comprensivo para la clasificación automática de la artrosis de rodilla basado en modelos CNN preentrenados y técnicas de inteligencia artificial explicable (XAI). Su metodología evalúa cinco arquitecturas (VGG-16, VGG-19, ResNet-50, ResNet-101 y EfficientNetB7) tanto en tareas multiclase (grados KL 0 a 4) como binarias, mediante un análisis sistemático de subgrupos (e.g., 0 vs. 1, 0 vs. 2, etc.). Además, aplican Grad-CAM para interpretar las regiones de interés utilizadas por los modelos en la toma de decisiones, comparándolas con las zonas anatómicas de evaluación clínica. Sus resultados destacan la dificultad de distinguir casos leves (KL1), coincidiendo con otros estudios, mientras que en escenarios binarios extremos (e.g., 0 vs. 4), EfficientNetB7 alcanza una precisión del 99.13 %. Esta propuesta resulta especialmente interesante para este TFG por su énfasis en interpretabilidad y comparación directa entre estrategias multiclase y binarias, lo cual aporta información clave sobre la viabilidad de cada enfoque diagnóstico en entornos reales.

Nabil et al. (2024) [nabil2024automatic] optan por una estrategia simplificada que agrupa las clases KL 0, 1 y 2 bajo la categoría “sano”, lo cual responde a la dificultad recurrente en la clasificación precisa del grado KL1. Comparan tres arquitecturas profundas —EfficientNetB7, DenseNet169 e InceptionResNetV2— y reportan un rendimiento superior de EfficientNetB7, con una precisión del 93.90 %. Su propuesta destaca por una cuidadosa fase de preprocesamiento, uso extensivo de técnicas de aumento de datos y regularización, así como una formulación del problema como clasificación en tres niveles (sano, moderado, severo). Pese a su elevado coste computacional, EfficientNetB7 se presenta como una solución idónea para entornos clínicos donde la precisión diagnóstica es prioritaria.

Fei et al. (2024) [fei2024diagnosing] plantean un cambio conceptual al abordar la clasificación de la artrosis como un problema de regresión continua, en lugar de una clasificación discreta. Utilizando redes neuronales convolucionales, sus modelos generan

puntuaciones decimales entre 0 y 4 que reflejan con mayor precisión la progresión de la enfermedad. Evalúan cuatro arquitecturas —VGG16, ResNet34, DenseNet196 y EfficientNetV2 small— sobre 8260 imágenes del dataset OAI, siendo EfficientNetV2 la más destacada, con una precisión del 71 %, AUC de 0.83 y un error absoluto medio (MAE) de 0.42. Este enfoque permite un análisis más granular y continuo del estado articular, abriendo la puerta a aplicaciones como el seguimiento longitudinal, la predicción de progresión y el soporte a la decisión clínica.

Cabe destacar que, al igual que la función de pérdida ajustable ordinal loss utilizada por Chen et al. (2019), el uso de una pérdida de tipo error cuadrático medio en este estudio refleja la intención de penalizar proporcionalmente según la distancia ordinal entre la predicción y la etiqueta real. Aunque desde una perspectiva técnica se trata de una formulación regresiva en lugar de categórica, ambas propuestas comparten el objetivo de capturar la estructura ordinal inherente al sistema de gradación de Kellgren-Lawrence, superando así las limitaciones de la entropía cruzada convencional.

En la Tabla 3.4 se presenta una síntesis comparativa de los principales trabajos analizados que han utilizado el dataset OAI. Se resumen los modelos empleados, el tipo de tarea formulada y la precisión obtenida en cada caso. Esta comparativa permite tener una visión global del panorama actual, así como identificar tendencias metodológicas relevantes para este TFG.

Tabla 3.4: Comparativa de tareas y resultados en el dataset OAI

Estudio	KL 0–4	KL 0*–3–4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
Chen et al. (2019)	70.4 %	–	–	–	–	–
Rafique et al. (2024)	58 %	–	78.11 %	82.33 %	91.53 %	99.13 %
Nabil et al. (2024)	–	94.09 %	–	–	–	–
Fei et al. (2024)	71 %	–	–	–	–	–

* 0 agrupa las clases KL 0, 1 y 2 como “sano”, frente a los grados 3 y 4 (“avanzado”).

El análisis de estos trabajos evidencia una creciente tendencia a incorporar la naturaleza ordinal del problema, así como a experimentar con formulaciones alternativas como la regresión o el uso de modelos ensamblados. Esta revisión proporciona una base sólida para el diseño experimental planteado en los capítulos siguientes, donde se compararán distintos enfoques de clasificación aplicados sobre el dataset OAI, considerando también la interpretación de resultados mediante técnicas como Grad-CAM.

3.5 Conclusiones

En este capítulo se ha presentado una visión integral de los recursos de datos utilizados en este Trabajo de Fin de Grado, destacando tanto el *dataset* OAI, ampliamente reconocido en la investigación médica para la artrosis de rodilla, como el *dataset* de gatos, que permite evaluar la generalización de los modelos desarrollados a un dominio anatómico distinto. La inclusión de estos dos conjuntos de datos, provenientes de contextos tan diversos, ha permitido establecer una base sólida para el desarrollo y la validación de modelos de clasificación profunda.

El *dataset* OAI se ha caracterizado en profundidad, especificando su estructura, distribución de clases y las particularidades de sus particiones. Esto ha puesto de manifiesto tanto su riqueza en términos de metadatos clínicos como el desafío del desbalance de clases inherente a la escala de severidad Kellgren-Lawrence (KL). Se ha evidenciado que este

desbalance constituye un reto metodológico que debe abordarse adecuadamente durante el diseño de los modelos de clasificación.

Por su parte, el *dataset* de gatos ha sido introducido como un conjunto adicional que facilita la evaluación de las capacidades de transferencia de los modelos desarrollados. Su menor tamaño y variabilidad en las condiciones de imagen plantean un escenario complementario y desafiante, idóneo para probar la robustez de las técnicas implementadas.

Finalmente, las tareas comunes definidas para ambos conjuntos de datos, desde la clasificación binaria hasta la clasificación ordinal, proporcionan un marco metodológico claro para el desarrollo de los modelos en los capítulos siguientes. La comprensión de estas tareas y sus variantes asegura una base conceptual sólida para el diseño experimental que se llevará a cabo, y permite contextualizar los resultados que se obtendrán.

CAPÍTULO 4

Redes Convolucionales

4.1 Introducción

En este capítulo se presentan los experimentos realizados con el objetivo de evaluar progresivamente distintas arquitecturas de redes neuronales en la tarea de clasificación automática del grado de artrosis de rodilla a partir de imágenes radiográficas.

Siguiendo una estrategia incremental, se parte del entrenamiento de modelos sencillos, como redes densas y pequeñas CNN diseñadas desde cero, para posteriormente avanzar hacia arquitecturas más complejas, finalizando con la aplicación de técnicas de *fine-tuning* sobre modelos preentrenados en grandes bases de datos generales, como ImageNet.

El planteamiento experimental ha sido diseñado para tratar de replicar y contrastar los resultados obtenidos en los principales trabajos revisados en el capítulo anterior, especialmente aquellos que han empleado el conjunto de datos derivado del estudio OAI [2]. Esta aproximación permite evaluar de forma objetiva el impacto de distintos niveles de complejidad arquitectónica en el rendimiento de la tarea, así como validar la efectividad del uso de aprendizaje por transferencia en el contexto biomédico.

4.2 Modelos

Con el objetivo de estudiar el efecto de la complejidad arquitectónica en el rendimiento del modelo, se diseñaron cinco redes neuronales convolucionales, siguiendo un esquema progresivo. Esta sección describe los tres primeros modelos, construidos desde cero, que sirven como base comparativa para los modelos preentrenados presentados posteriormente.

CNN simple. Este modelo constituye una línea base minimalista, con una única capa convolucional que permite extraer características elementales como bordes y texturas. Presenta un número muy reducido de parámetros, lo que se traduce en tiempos de entrenamiento bajos. Su principal utilidad reside en proporcionar una referencia con la que contrastar modelos más complejos.

- `Conv2D(16, kernel_size=3x3, activation='relu', input_shape=(224, 224, 3))`
- `MaxPooling2D(pool_size=2x2)`
- `Flatten()`
- `Dense(num_classes, activation='softmax' if classification else 'linear')`

Aunque su capacidad de representación es limitada, este modelo resulta clave para identificar el impacto marginal de cada capa adicional sobre el rendimiento general del sistema.

CNN mediana. Este segundo modelo introduce una segunda capa convolucional y una capa densa intermedia, lo que le otorga mayor capacidad para extraer y combinar patrones espaciales complejos. El incremento en profundidad y en el número de filtros permite detectar características jerárquicas más ricas en las imágenes.

- `Conv2D(32, 3x3, activation='relu', padding='same', input_shape=(..., ..., 1))`
- `MaxPooling2D(2x2)`
- `Conv2D(64, 3x3, activation='relu', padding='same')`
- `MaxPooling2D(2x2)`
- `Flatten()`
- `Dense(128, activation='relu')`
- `Dense(num_classes, activation='softmax')`

Este modelo representa un equilibrio entre simplicidad y expresividad, ideal para analizar cómo la profundidad de la red y la cantidad de filtros afectan a la precisión en la clasificación.

CNN profunda. El tercer modelo incrementa notablemente la complejidad mediante la incorporación de tres bloques convolucionales con normalización por lotes (*Batch Normalization*) y regularización mediante *Dropout*. Esta arquitectura está diseñada para aumentar la capacidad del modelo manteniendo su capacidad de generalización y reduciendo el riesgo de sobreajuste.

■ **Bloque 1:**

- `Conv2D(32, 3x3, activation='relu', padding='same', input_shape=(..., ..., 1))`
- `BatchNormalization()`
- `Conv2D(32, 3x3, activation='relu', padding='same')`
- `BatchNormalization()`
- `MaxPooling2D(2x2)`
- `Dropout(0.25)`

■ **Bloque 2:**

- `Conv2D(64, 3x3, activation='relu', padding='same')`
- `BatchNormalization()`
- `Conv2D(64, 3x3, activation='relu', padding='same')`
- `BatchNormalization()`
- `MaxPooling2D(2x2)`
- `Dropout(0.25)`

■ **Bloque 3:**

- `Conv2D(128, 3x3, activation='relu', padding='same')`
- `BatchNormalization()`
- `Conv2D(128, 3x3, activation='relu', padding='same')`
- `BatchNormalization()`
- `MaxPooling2D(2x2)`
- `Dropout(0.4)`

■ **Clasificación:**

- `Flatten()`
- `Dense(256, activation='relu')`
- `BatchNormalization()`
- `Dropout(0.5)`
- `Dense(num_classes, activation='softmax')`

Gracias a esta estructura jerárquica y regularizada, el modelo es capaz de aprender representaciones más abstractas y complejas, lo que resulta especialmente útil en el análisis de imágenes médicas donde los detalles sutiles pueden ser determinantes para la clasificación. El uso de normalización y regularización permite entrenar arquitecturas profundas sin incurrir en problemas de inestabilidad numérica o sobreajuste excesivo.

Modelo 4: **EfficientNetB0**

Modelo 5: **resnetAlfons** o **ResNet50**

4.3 Experimentos

El diseño experimental de este trabajo se ha estructurado para evaluar el impacto de la complejidad arquitectónica y la transferencia de conocimiento en la tarea de clasificación de artrosis de rodilla. Para ello, se han entrenado y comparado cinco modelos representativos bajo condiciones homogéneas.

Comparación de modelos con distinta complejidad. Se han considerado cinco arquitecturas con creciente capacidad de representación: tres modelos construidos desde cero (CNN simple, CNN pequeña y CNN profunda) y dos modelos preentrenados (EfficientNetB0 y ResNet50), ajustados mediante *transfer learning*. Esta selección permite analizar la relación entre la expresividad del modelo, el coste computacional y la capacidad de generalización, tanto dentro del dominio (OAI) como fuera de él (radiografías de gatos).

Configuración común de entrenamiento. Todos los modelos se han entrenado con los mismos hiperparámetros base: optimizador Adam, tasa de aprendizaje inicial de 10^{-3} , función de pérdida `CrossEntropyLoss`, tamaño de lote de 32 y un máximo de 50 épocas. Se ha aplicado *early stopping* con paciencia de 10 épocas sin mejora en el conjunto de validación, y un *scheduler* de tasa de aprendizaje con factor de reducción de 0.5 tras 5 épocas sin mejora.

En el caso de los modelos preentrenados, se han evaluado dos variantes: (i) congelando inicialmente el *backbone* y afinando solo las capas finales; y (ii) realizando un ajuste fino completo. En ambos casos se ha empezado con una tasa de aprendizaje más baja (10^{-4}) debido a la mayor complejidad de los modelos y la posibilidad de sobreajuste. Esta estrategia busca maximizar la transferencia de conocimiento y minimizar el riesgo de inestabilidad durante el entrenamiento.

División de datos y normalización. Todos los entrenamientos se han realizado utilizando las particiones oficiales del dataset OAI (train, validation, test), manteniendo su integridad para asegurar la replicabilidad. Las imágenes fueron redimensionadas a 224x224 píxeles y normalizadas para su compatibilidad con modelos preentrenados.

Evaluación en dominio externo: dataset felino. Como medida de validación externa, se ha utilizado un conjunto adicional de imágenes de radiografías de gatos. Durante el entrenamiento, este conjunto se ha empleado como evaluación secundaria (no influenciada por el *early stopping* ni el *scheduler*) para estimar la capacidad de generalización de los modelos a un dominio visual distinto pero clínicamente análogo. Para cada modelo se ha conservado la mejor versión según la validación humana y otra según el rendimiento en gatos.

Métricas de evaluación. El rendimiento de cada arquitectura se ha evaluado mediante varias métricas: precisión global (*accuracy*), F1-score macro, matriz de confusión y error absoluto medio (MAE) para formulaciones ordinales. Estas métricas se han aplicado tanto al conjunto de test del dataset OAI como al conjunto felino, permitiendo un análisis cruzado entre dominios. Para la comparación de modelos se ha utilizado la precisión global como métrica principal.

Técnicas de regularización y aumento de datos. Los modelos diseñados desde cero incluyen mecanismos de regularización como Dropout y BatchNormalization, cruciales para mejorar la estabilidad del entrenamiento y mitigar el sobreajuste. Además, se ha implementado *data augmentation* en tiempo real: rotaciones aleatorias, reflejos verticales y horizontales, y variaciones de brillo y contraste. Estas transformaciones buscan enriquecer la variabilidad del conjunto de entrenamiento y mejorar la robustez del modelo.

Resultados obtenidos Este apartado presenta de forma detallada los resultados experimentales obtenidos a lo largo del desarrollo del presente Trabajo de Fin de Grado. La evaluación de los modelos diseñados se ha centrado en analizar el impacto de la arquitectura, la formulación del problema (clasificación vs. regresión) y la partición de tareas (multiclase, binaria y ordinal) sobre la capacidad del sistema para predecir de forma automática el grado de artrosis de rodilla a partir de radiografías del conjunto de datos OAI.

En línea con los estudios revisados en el capítulo anterior, los experimentos se han concebido de forma progresiva, comenzando por modelos simples construidos desde cero y avanzando hacia arquitecturas más complejas y robustas. Esta progresión arquitectónica permite establecer una base comparativa sólida y observar cómo se incrementa la capacidad de representación de los modelos a medida que se introducen nuevas técnicas de normalización, regularización y profundidad.

Evaluación de modelos simples construidos desde cero. El primer bloque de resultados corresponde a las tres CNN personalizadas (simple, mediana y profunda), entrenadas desde cero. El propósito inicial de estos modelos no es alcanzar una precisión máxima, sino establecer una línea base interpretativa que permita entender qué nivel de rendimiento puede obtenerse sin recurrir al aprendizaje por transferencia ni a arquitecturas sofisticadas. Así, la *Simple CNN*, con una única capa convolucional y una densidad de parámetros mínima, permite observar la capacidad de generalización más básica del sistema.

En las tareas multiclase (KL 0 a 4), el modelo simple logra una precisión del 42 % y un F1-score del 30 %, lo que evidencia sus limitaciones para discriminar clases ordinales cercanas. No obstante, en tareas binarias extremas como KL 0 vs KL 4, la precisión asciende al 97.18 %, con un F1-score de 97.02 %, revelando que incluso modelos muy básicos pueden captar diferencias marcadas cuando las clases son visualmente muy dispares. Este comportamiento sugiere que la dificultad no reside únicamente en el modelo, sino en la

naturaleza ambigua de los casos intermedios (KL1, KL2), en línea con lo reportado por Rafique et al. (2024).

La *CNN mediana*, con dos capas convolucionales y una capa densa intermedia, introduce una mejora sustancial al permitir la detección de patrones jerárquicos más complejos. Su rendimiento en clasificación multiclase asciende al 46.85 %, con un F1-score del 39.71 %. La mejora más significativa se observa en tareas como 0 vs 3 y 0 vs 4, donde supera el 84 % y el 97 % de precisión, respectivamente. Estos resultados reflejan que con un incremento moderado en la profundidad y la capacidad de abstracción del modelo, se logran mejoras tangibles en la discriminación de clases intermedias.

Por su parte, la *CNN profunda*, estructurada en tres bloques con BatchNormalization y Dropout, consigue consolidarse como la mejor red entre las diseñadas ad-hoc. En clasificación multiclase alcanza una precisión del 58.47 % y un F1-score del 52.03 %, lo que representa una mejora absoluta de más de 16 puntos respecto al modelo simple. En tareas binarias, destaca especialmente en las comparaciones intermedias (0 vs 2, 0 vs 3), donde su rendimiento supera ampliamente el 85 %, y alcanza el 99.72 % en la comparación 0 vs 4, con un F1-score idéntico. Estos resultados evidencian el papel crucial que desempeñan las técnicas de regularización en la mejora de la generalización.

Resultados en formulación ordinal (regresión). Además de la clasificación categórica, se ha explorado una formulación regresiva del problema, utilizando las mismas arquitecturas pero adaptando la función de pérdida a un error cuadrático medio (MSE). Esta aproximación tiene como objetivo capturar la continuidad inherente al sistema de gradación Kellgren-Lawrence, penalizando más severamente los errores proporcionales a la distancia ordinal entre la predicción y la etiqueta real.

En esta configuración, los modelos muestran una tendencia coherente con lo observado en clasificación: la CNN profunda obtiene el mejor MAE (0.651), seguida por la CNN mediana (0.771) y la simple (0.897). De manera interesante, se observa que la formulación regresiva permite obtener mejores resultados en tareas reagrupadas (0-3-4), donde la CNN profunda alcanza un 84.34 % de precisión y un F1-score de 77.17 %, siendo este un resultado comparable al de estudios como Fei et al. (2024), quienes defienden también el enfoque continuo como una vía prometedora en tareas clínicas.

En esta segunda parte se presentan los resultados obtenidos al aplicar técnicas de *transfer learning* sobre dos arquitecturas profundas ampliamente utilizadas en visión por computador: EfficientNetB0 y ResNet50. A diferencia de los modelos diseñados desde cero, estas redes aprovechan conocimiento previamente aprendido sobre grandes bases de datos como ImageNet, lo que permite partir de representaciones visuales genéricas y afinarlas para la tarea específica de clasificación de la artrosis.

Resultados con EfficientNetB0. Este modelo ha destacado especialmente por su eficiencia y capacidad de generalización con un número relativamente reducido de parámetros. En su configuración óptima (ajuste fino completo), alcanza una precisión del 68.64 % en la tarea multiclase (KL 0-4), con un F1-score del 64.82 %. Estas cifras superan ampliamente las obtenidas por las CNN propias, con una mejora de más de 10 puntos porcentuales respecto al mejor modelo desde cero.

En las tareas binarias, EfficientNetB0 obtiene resultados notablemente altos, con una precisión del 94.07 % en la tarea 0-3-4 y del 97.70 % en 0 vs 3, consolidando su robustez en escenarios de clasificación clínica práctica. La formulación ordinal mediante regresión también resulta efectiva, alcanzando un MAE de solo 0.463 y una precisión del 65.13 %, lo que respalda la hipótesis de que estas arquitecturas permiten capturar mejor la continuidad inherente al grado de artrosis.

Evaluación cruzada en el dominio felino. Uno de los objetivos específicos de este TFG ha sido evaluar la capacidad de generalización de los modelos desarrollados a un dominio anatómicamente distinto: el conjunto de imágenes radiográficas de gatos. Aunque este conjunto es de menor tamaño y presenta mayor variabilidad en las condiciones de adquisición, se ha mantenido como evaluación externa sin intervenir en los procesos de entrenamiento o validación.

Los resultados obtenidos muestran que los modelos preentrenados (especialmente EfficientNetB0) conservan un nivel razonable de precisión en este dominio externo, validando así la aplicabilidad del aprendizaje por transferencia inter-especie. Esta observación abre nuevas líneas de investigación en contextos veterinarios, donde los conjuntos de datos suelen ser mucho más escasos.

Comparativa global y análisis. En la Figura ?? se presenta una comparativa gráfica de la precisión multiclase (KL 0-4) alcanzada por los distintos modelos, permitiendo visualizar de forma directa la evolución del rendimiento conforme aumenta la complejidad de la arquitectura. Del mismo modo, la Tabla ?? recoge de forma sintética las principales métricas (accuracy, F1, MAE) para cada configuración relevante.

Como puede observarse, la precisión y el F1-score mejoran de forma sostenida con el aumento de complejidad, y los modelos preentrenados presentan una clara ventaja en formulaciones multiclase. En tareas binarias extremas, sin embargo, incluso las CNN más simples alcanzan niveles notables, lo que refuerza la idea de que el grado de separación entre clases influye significativamente en la dificultad del problema.

4.4 Conclusiones

Los resultados obtenidos no solo confirman la viabilidad del uso de redes neuronales profundas para la clasificación automática de la artrosis de rodilla, sino que también validan el enfoque de este TFG al estructurar la evaluación de forma progresiva y comprensiva. La introducción de una evaluación interdominio basada en radiografías de gatos, aunque secundaria en este capítulo, ha servido para comprobar la robustez de los modelos desarrollados, lo que constituye una de las principales contribuciones del trabajo.

En los capítulos siguientes se analizarán más a fondo las interpretaciones clínicas de los resultados, así como la visualización de activaciones mediante Grad-CAM, con el objetivo de avanzar hacia sistemas de ayuda a la decisión médica más transparentes y explicables.

Resultados simple CNN:

Tabla 4.1: Resultados Simple CNN en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	42 %	85.35 %	68.19 %	65.37 %	80.88 %	97.18 %
	Clasif.	F1-score	30 %	80.35 %	55.29 %	62.84 %	77.98 %	97.02 %
OAI	Regr.	Accuracy	34.87 %	84.38 %	–	–	–	–
	Regr.	F1-score	34.65 %	78.16 %	–	–	–	–
	Regr.	MAE	0.897	0.291	–	–	–	–

Resultados CNN mediana:

Resultados CNN grende:

Tabla 4.2: Resultados CNN mediana en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	46.85 %	85.35 %	68.19 %	62.41 %	84.10 %	97.46 %
	Clasif.	F1-score	39.71 %	80.35 %	55.29 %	54.41 %	82.16 %	97.35 %
OAI	Regr.	Accuracy	34.87 %	84.02 %	—	—	—	—
	Regr.	F1-score	34.65 %	82.71 %	—	—	—	—
	Regr.	MAE	0.771	0.237	—	—	—	—

Tabla 4.3: Resultados CNN grande en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	58.47 %	89.35 %	68.40 %	74.26 %	86.64 %	99.72 %
	Clasif.	F1-score	52.03 %	88.50 %	55.78 %	72.51 %	86.14 %	99.72 %
OAI	Regr.	Accuracy	43.95 %	84.34 %	—	—	—	—
	Regr.	F1-score	46.22 %	77.17 %	—	—	—	—
	Regr.	MAE	0.651	0.171	—	—	—	—

Resultados EfficientNetB0:**Tabla 4.4:** Resultados EfficientNetB0 en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	68.64 %	94.07 %	74.01 %	87.22 %	97.70 %	99.72 %
	Clasif.	F1-score	64.82 %	93.84 %	71.78 %	87.77 %	97.67 %	99.72 %
OAI	Regr.	Accuracy	65.13 %	93.83 %	—	—	—	—
	Regr.	F1-score	65.84 %	93.67 %	—	—	—	—
	Regr.	MAE	0.463	0.102	—	—	—	—

Tabla 4.5: Resultados ResNet151 en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	67.07 %	95.16 %	68.61 %	86.67 %	96.31 %	100 %
		F1-score	67.19 %	94.89 %	65.26 %	86.55 %	96.26 %	100 %
OAI	Regr.	Accuracy	59.56 %	82.93 %				
		F1-score	61.40 %	79.17 %				
		MAE	0.515	0.342				

CAPÍTULO 5

Transformers

5.1 Introducción

En este capítulo se presenta el uso de modelos Transformers en la clasificación automática del grado de artrosis de rodilla a partir de imágenes radiográficas. Los Transformers, introducidos inicialmente para tareas de procesamiento de lenguaje natural, han demostrado un rendimiento sobresaliente en visión por computadora gracias a su capacidad para capturar relaciones globales en las imágenes mediante mecanismos de atención.

El planteamiento experimental sigue una estrategia progresiva, comenzando con modelos Transformer básicos como Vision Transformer (ViT) y avanzando hacia arquitecturas más sofisticadas como Swin Transformer y variantes híbridas que combinan bloques convolucionales y transformadores. Este enfoque permite analizar cómo el uso de atención global y local impacta en el rendimiento de la clasificación.

5.2 Modelos

Para evaluar el desempeño de los Transformers en esta tarea, se han seleccionado tres arquitecturas representativas:

Vision Transformer (ViT). Un modelo Transformer puro que divide las imágenes en parches y aplica atención auto-regresiva para capturar relaciones globales entre estos. Su simplicidad y capacidad de escalabilidad lo convierten en un buen punto de partida.

5.3 Experimentos

Los experimentos se han diseñado para evaluar el rendimiento de los modelos Transformer bajo condiciones homogéneas, utilizando las mismas configuraciones de entrenamiento que en el capítulo anterior:

- Optimizer: Adam
- Learning Rate: 10^{-4}
- Loss Function: CrossEntropyLoss
- Batch Size: 32
- Early Stopping: 10 epochs

- Learning Rate Scheduler: Factor 0.5 after 5 epochs

Se han entrenado los modelos en el conjunto de datos OAI, y se ha realizado una evaluación cruzada utilizando un conjunto externo de imágenes de radiografías de gatos, para analizar su capacidad de generalización.

Métricas de evaluación. Las métricas utilizadas para comparar el rendimiento de los modelos son:

- Precisión global (Accuracy)
- F1-Score macro
- Matriz de confusión
- MAE (Mean Absolute Error)

Aumento de datos y regularización. Se ha aplicado aumento de datos en tiempo real, incluyendo rotaciones aleatorias, reflejos y variaciones de brillo y contraste. Además, se ha utilizado Dropout y Normalización por Lotes para mejorar la generalización.

Tabla 5.1: Resultados de google/vit-base-patch16-224

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	65.45 %	92.37 %	69.64 %	80.74 %	96.54 %	99.44 %
		F1-score	63.48 %	82.38 %	48.31 %	80.00 %	95.24 %	98.00 %
OAI	Regr.	Accuracy	68.70 %	91.71 %				
		F1-score	64.70 %	90.20 %				
		MAE	0.4617	0.0603				

Evaluación en dominio externo. Se ha evaluado el rendimiento de los modelos en un conjunto adicional de imágenes de radiografías de gatos, replicando las condiciones de evaluación establecidas para los modelos convolucionales.

CAPÍTULO 6

Fine-tuning para radiografías de gatos

6.1 Introducción

La aplicación directa de modelos entrenados sobre radiografías humanas al dominio veterinario supone un reto interesante desde el punto de vista del aprendizaje por transferencia. En este capítulo se evalúa la viabilidad de adaptar modelos entrenados en el conjunto OAI a radiografías de rodillas de gatos, analizando su rendimiento y capacidad de generalización ante un cambio anatómico y de dominio visual.

6.2 Selección de tareas y análisis de sentido clínico

Dado el reducido tamaño del conjunto felino y la subjetividad de las clases más leves, se ha llevado a cabo una selección de 2 tareas, la primera consiste en la tarea principal (0vs1vs2vs3vs4). La segunda tarea consiste en clasificación de 2 clases, la clase "sin artrosis"(0 y 1) y la clase con artrosis 2,3,4

6.3 Experimentos realizados

Los experimentos realizados consiste en estas 2 tareas con dos modelos (Efficient-NetB0 y el transformer de google). En cada experimento se han probado 3 tipos de entrenamiento: - Entrenamiento directo sobre el dataset de los gatos utilizando los modelos preentrenados de serie - Entrenamiento indirecto, utilizando los modelos previamente entrenados se ha evaluado directamente sobre el dataset sin realizar ningún entrenamiento extra - Finetuning, utilizanod los modelos preentrenados previamente, se ha reentrenado con el dataset de gatos dejando un 35 % de los datos para validación (30 imagenes) y así tener una muestra representativa de las clases teniendo en los casos más críticos 1 imagen de la clase 4 y 3 de la clase 3

6.4 Resultados y análisis

A continuación, se muestran los principales resultados obtenidos en las tareas más representativas:

Tabla 6.1: Resultados de la Tarea 0–4 para ViT y EfficientNetB0 con distintos tipos de entrenamiento

Modelo	Métrica	Directo	Indirecto	Finetuning
ViT (Google)	Accuracy	47 %	29 %	50 %
	F1-score	44 %	27 %	51 %
EfficientNetB0	Accuracy	40 %	17 %	30 %
	F1-score	39 %	9 %	22 %

Tabla 6.2: REGRESSION - Resultados de la Tarea 0–4 para ViT y EfficientNetB0 con distintos tipos de entrenamiento

Modelo	Métrica	Directo	Indirecto	Finetuning
ViT (Google)	Accuracy	33 %	39 %	47 %
	F1-score	33 %	39 %	47 %
	MAE	0.831	0.842	0.669
EfficientNetB0	Accuracy	30 %	33 %	40 %
	F1-score	30 %	13 %	40 %
	MAE	1.011	0.935	0.747

Se observa que las tareas con mayor contraste (como 0 vs 4) obtienen métricas superiores, mientras que las tareas intermedias presentan un rendimiento más limitado. Esto sugiere que el conocimiento transferido se mantiene robusto ante diferencias notables, pero pierde precisión en clases ambiguas.

6.5 Conclusiones

Los modelos preentrenados en humanos pueden ser ajustados con éxito para detectar artrosis en gatos, especialmente en tareas con diferencias claras entre clases. El uso de fine-tuning parcial y aumento de datos ha sido clave para mitigar el impacto del reducido tamaño del conjunto felino. Sin embargo, las tareas con clases cercanas siguen suponiendo un reto significativo, lo que motiva futuras líneas de trabajo enfocadas en preprocesamiento adaptado y reetiquetado colaborativo con expertos veterinarios.

Tabla 6.3: Resultados de la Tarea 01vs234 para ViT y EfficientNetB0 con distintos tipos de entrenamiento

Modelo	Métrica	Directo	Indirecto	Finetuning
ViT (Google)	Accuracy	67 %	37 %	80 %
	F1-score	68 %	20 %	79 %
EfficientNetB0	Accuracy	70 %	42 %	73 %
	F1-score	69 %	40 %	73 %

CAPÍTULO 7

Conclusiones

7.1 Resumen del trabajo realizado

7.2 Objetivos alcanzados

7.3 Trabajo futuro

Bibliografía

- [1] Amazon Web Services. *Model Fit: Underfitting vs. Overfitting*. <https://docs.aws.amazon.com/machine-learning/latest/dg/model-fit-underfitting-vs-overfitting.html>. Consultado el 9 de abril de 2025. 2023.
- [2] Pingjun Chen. *Knee Osteoarthritis Severity Grading Dataset*. Ver. V1. Mendeley Data, 2018. DOI: [10.17632/56rmx5bjcr.1](https://doi.org/10.17632/56rmx5bjcr.1).
- [3] Pingjun Chen et al. "Fully automatic knee osteoarthritis severity grading using deep neural networks with a novel ordinal loss". En: *Computerized Medical Imaging and Graphics* 75 (jul. de 2019), págs. 84-92. DOI: [10.1016/j.compmedimag.2019.06.002](https://doi.org/10.1016/j.compmedimag.2019.06.002). URL: <https://doi.org/10.1016/j.compmedimag.2019.06.002>.
- [4] Logongas. *Backpropagation y descenso del gradiente*. https://logongas.es/doku.php?id=clase:iabd:pia:2eval:tema07.backpropagation_descenso_gradiente. Consultado el 9 de abril de 2025. 2023.

APÉNDICE A

Configuración del sistema

APÉNDICE B

Otro apéndice
