



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Escola Tècnica
Superior d'Enginyeria
Informàtica

Escuela Técnica Superior de Ingeniería Informática
Universidad Politécnica de Valencia

Clasificación automática de artrosis en rodillas mediante redes neuronales convolucionales

TRABAJO FIN DE GRADO

Grado en Ingeniería Informática

Autor: Hernández Martínez, Carlos

Tutor: Juan Ciscar, Alfonso

Curso 2024-2025

Resumen

Este Trabajo de Fin de Grado presenta el diseño, implementación y evaluación de un sistema de **clasificación automática de artrosis de rodilla** a partir de radiografías, empleando técnicas de *aprendizaje profundo*. Se aborda la problemática clínica de la **variabilidad interobservador** y la **subjetividad** inherentes al diagnóstico radiográfico tradicional, proponiendo modelos capaces de estandarizar y objetivar la estimación de severidad según la *escala Kellgren–Lawrence* (KL, 0–4).

Como base de datos principal se utiliza una versión curada del *Osteoarthritis Initiative* (OAI), con cerca de 9.800 imágenes de rodilla etiquetadas con KL, que presenta un notable **desbalance de clases**. Se adopta un **enfoque incremental**: (i) tres *CNN* diseñadas desde cero para establecer líneas base; (ii) **modelos preentrenados** mediante *transfer learning* (*EfficientNetB0* y *ResNet50*) con variantes de congelación y ajuste fino; y (iii) la evaluación de un *Transformer* de visión (*ViT-base patch16*) como alternativa no convolucional. Todos los modelos comparten un protocolo de entrenamiento unificado (optimizador Adam, *early stopping*, planificador de tasa de aprendizaje), **aumento de datos** (rotación, volteos, ajuste de brillo/contraste) y evaluación mediante *accuracy*, *F1-score* y *MAE*. **Para interpretabilidad**, se emplea *Grad-CAM* para verificar la atención sobre regiones anatómicas relevantes.

En OAI, las *CNN* profundas y, especialmente, las arquitecturas **preentrenadas** muestran una clara ventaja sobre los modelos desde cero. *EfficientNetB0* alcanza $\approx 68,6\%$ de *accuracy*, $\approx 64,8\%$ de *F1* y *MAE* $\approx 0,46$ en la versión regresiva; *ViT* obtiene resultados cercanos ($\approx 65,5\%$). En comparaciones binarias extremas (KL0 vs KL4), todas las arquitecturas superan el 99 %, confirmando que la dificultad radica en grados intermedios.

Como **validación externa**, se estudia la *transferencia interdominio* hacia un conjunto de 82 radiografías de rodilla felinas etiquetadas con KL. Se comparan tres regímenes: inferencia sin ajuste, entrenamiento directo y *fine-tuning* desde pesos entrenados en OAI. El *fine-tuning* logra la mejor generalización, alcanzando $\approx 80\%$ de *accuracy* (*ViT*) en clasificación binaria, mientras que la clasificación completa 0–4 sigue siendo un reto ($\approx 50\%$).

Este TFG **demuestra la viabilidad** de las *CNN* y *Transformers* como herramientas de apoyo al diagnóstico de la artrosis de rodilla, **valida el *transfer learning*** en contextos clínicos y **abre la puerta** a su uso en el ámbito veterinario. Persisten retos como el **desbalance de clases**, la **ambigüedad en grados leves**, el **tamaño reducido de muestras** y la **calibración** de modelos.

Palabras clave: artrosis de rodilla; redes neuronales convolucionales; aprendizaje profundo; aprendizaje por transferencia; Grad-CAM; diagnóstico asistido por ordenador; transferencia interdominio

Abstract

This Final Degree Project presents the design, implementation, and evaluation of a system for **automatic classification of knee osteoarthritis** from radiographs, using *deep learning* techniques. It addresses the clinical issue of **inter-observer variability** and **subjectivity** inherent in traditional radiographic diagnosis, proposing models capable of standardizing and objectifying severity estimation according to the *Kellgren-Lawrence* scale (KL, 0–4).

The main dataset used is a curated version of the *Osteoarthritis Initiative* (OAI), with approximately 9,800 knee images labeled with KL, presenting a notable **class imbalance**. An **incremental approach** was adopted: (i) three CNN architectures designed from scratch to establish baselines; (ii) **pretrained models** via *transfer learning* (*EfficientNetB0* and *ResNet50*) with variants of freezing and fine-tuning; and (iii) the evaluation of a vision *Transformer* (*ViT-base patch16*) as a non-convolutional alternative. All models follow a unified training protocol (Adam optimizer, *early stopping*, learning rate scheduler), **data augmentation** (rotation, flipping, brightness/contrast adjustment), and evaluation using *accuracy*, *F1-score*, and *MAE*. For **interpretability**, *Grad-CAM* was used to verify attention over relevant anatomical regions.

In OAI, deep CNNs and especially **pretrained** architectures show a clear advantage over models trained from scratch. *EfficientNetB0* reaches $\approx 68.6\%$ *accuracy*, $\approx 64.8\%$ *F1*, and *MAE* ≈ 0.46 in the regression version; *ViT* achieves similar results ($\approx 65.5\%$). In extreme binary comparisons (KL0 vs KL4), all architectures surpass 99%, confirming that the difficulty lies in intermediate grades.

As **external validation**, a *cross-domain transfer* study was conducted using a set of 82 feline knee radiographs labeled with KL. Three regimes were compared: inference without adjustment, full training, and *fine-tuning* from OAI-trained weights. *Fine-tuning* achieves the best generalization, reaching $\approx 80\%$ *accuracy* (*ViT*) in binary classification, while full 0–4 classification remains challenging ($\approx 50\%$).

This work **demonstrates the feasibility** of CNNs and *Transformers* as tools to support the diagnosis of knee osteoarthritis, **validates transfer learning** in clinical contexts, and **opens the door** to its application in the veterinary field. Challenges remain, such as **class imbalance**, **ambiguity in mild grades**, **small sample sizes**, and **model calibration**.

Key words: knee osteoarthritis; convolutional neural networks; deep learning; transfer learning; Grad-CAM; computer-aided diagnosis; cross-domain transfer

Resum

Aquest Treball de Fi de Grau presenta el disseny, implementació i avaluació d'un sistema de **classificació automàtica d'artrosi de genoll** a partir de radiografies, emprant tècniques d'*aprenentatge profund*. Aborda la problemàtica clínica de la **variabilitat interobservador** i la **subjectivitat** inherent al diagnòstic radiogràfic tradicional, proposant models capaços d'estandarditzar i objectivar l'estimació de la severitat segons l'*escala Kellgren-Lawrence* (KL, 0–4).

La base de dades principal és una versió curada de l'*Osteoarthritis Initiative* (OAI), amb prop de 9.800 imatges de genoll etiquetades amb KL, que presenta un destacat **desbalanceig de classes**. S'ha adoptat un **enfocament incremental**: (i) tres arquitectures CNN dissenyades des de zero per establir línies de base; (ii) **models preentrenats** mitjançant *transfer learning* (*EfficientNetB0* i *ResNet50*) amb variants de congelació i ajust fi; i (iii) l'avaluació d'un *Transformer* de visió (*ViT-base patch16*) com a alternativa no convolucional. Tots els models segueixen un protocol d'entrenament unificat (optimitzador Adam, *early stopping*, planificador de taxa d'aprenentatge), **augment de dades** (rotació, volteig, ajust de brillantor/contrast) i avaluació amb *accuracy*, *F1-score* i MAE. Per a la **interpretabilitat**, s'ha utilitzat *Grad-CAM* per verificar l'atenció sobre regions anatòmiques rellevants.

En OAI, les CNN profundes i, especialment, les arquitectures **preentrenades** mostren un clar avantatge respecte als models des de zero. *EfficientNetB0* aconsegueix $\approx 68,6\%$ *accuracy*, $\approx 64,8\%$ *F1* i MAE $\approx 0,46$ en la versió regressiva; *ViT* obté resultats similars ($\approx 65,5\%$). En comparacions binàries extremes (KL0 vs KL4), totes les arquitectures superen el 99%, confirmant que la dificultat es troba en graus intermedis.

Com a **validació externa**, s'ha realitzat un estudi de *transferència interdomini* amb un conjunt de 82 radiografies de genoll felines etiquetades amb KL. S'han comparat tres règims: inferència sense ajust, entrenament complet i *fine-tuning* a partir de pesos entrenats en OAI. El *fine-tuning* aconsegueix la millor generalització, arribant a $\approx 80\%$ *accuracy* (*ViT*) en classificació binària, mentre que la classificació completa 0–4 continua sent un repte ($\approx 50\%$).

Aquest treball **demostra la viabilitat** de les CNN i *Transformers* com a eines de suport al diagnòstic de l'artrosi de genoll, **valida el *transfer learning*** en contextos clínics i **obre la porta** a la seua aplicació en l'àmbit veterinari. Persisteixen reptes com el **desbalanceig de classes**, l'**ambigüitat en graus lleus**, la **mida reduïda de mostres** i la **calibració dels models**.

Paraules clau: artrosi de genoll; xarxes neuronals convolucionals; aprenentatge profund; aprenentatge per transferència; Grad-CAM; diagnòstic assistit per ordinador; transferència interdominial

Índice general

Índice general	VII
Índice de figuras	IX
Índice de tablas	X
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos del TFG	2
2 Preliminares	5
2.1 Aprendizaje automático	5
2.2 Redes Neuronales	8
2.3 Aprendizaje automático en imágenes médicas	11
3 Descripción de los datasets y tareas comunes	15
3.1 Introducción	15
3.2 Dataset OAI	16
3.3 Dataset de gatos	18
3.4 Tareas comunes	20
3.5 Conclusiones	22
4 Redes Convolucionales	25
4.1 Introducción	25
4.2 Modelos	26
4.3 Experimentos	29
4.4 Conclusiones	34
5 Transformers	37
5.1 Introducción	37
5.2 Modelos	37
5.3 Experimentos	38
5.4 Conclusiones	40
6 Fine-tuning para radiografías de gatos	41
6.1 Introducción	41
6.2 Selección de tareas y análisis de sentido clínico	41
6.3 Experimentos realizados	42
6.4 Interpretabilidad mediante Grad-CAM	45
6.5 Conclusiones	46
7 Conclusiones	49
7.1 Resumen del trabajo realizado	49
7.2 Objetivos alcanzados	49
7.3 Trabajo futuro	49
Apéndices	
A Configuración del sistema	53
B Otro apéndice	55

Índice de figuras

2.1	Ejemplo ilustrativo de subajuste, buen ajuste y sobreajuste en un modelo supervisado. Adaptado de [1].	5
2.2	Flujo de entrenamiento de un modelo supervisado mediante descenso de gradiente. Adaptado de [13].	6
2.3	Ilustración del compromiso sesgo-varianza: relación entre la complejidad del modelo y el error de entrenamiento y validación. [7]	7
2.4	Ejemplo de una red neuronal profunda [neural_network]	8
2.5	Ejemplo de arquitectura de una red neuronal convolucional para clasificación de imágenes. Se observan capas convolucionales (conv) que aplican filtros aprendibles sobre la imagen de entrada, seguidas de capas de pooling que reducen la resolución. Al final, capas totalmente conectadas (FC) procesan las características extraídas para producir la clasificación en alguna de las categorías.	9
2.6	Esquema de Vision Transformer (ViT): la imagen se divide en parches que se proyectan a embeddings, se añade codificación posicional y se procesan mediante bloques de autoatención. Un token especial de clase (<i>class token</i>) permite la clasificación final, aprovechando el mecanismo de atención para capturar relaciones globales entre todas las regiones de la imagen. [5] . . .	10
3.1	Ejemplos de radiografías de rodilla correspondientes a los cinco grados de la escala Kellgren-Lawrence (KL).	17
3.2	Distribución porcentual de las clases KL (0-4) en las particiones de entrenamiento, validación y prueba del dataset OAI. Se observa un predominio de las categorías más leves en <i>train</i> y <i>val</i> , y una representación mayor de grados avanzados en <i>test</i>	18
3.3	Distribución porcentual de radiografías felinas según la escala KL. Se observa una clara predominancia de casos sin artrosis o con artrosis ligera. .	19
3.4	Matriz de confusión agregada en la clasificación multiclase KL 0-4 con el mejor modelo de Fei et al. (2024)[fei2024diagnosing]. Predominan los aciertos en la diagonal y las confusiones entre clases vecinas, especialmente KL1-KL2.	22
4.1	Esquema <i>AlexNet-style</i> de la CNN simple (línea base)	27
4.2	Esquema <i>AlexNet-style</i> de la CNN intermedia	27
4.3	Arquitectura <i>CNN_Profunda</i> implementada en Keras: tres bloques Conv-BN-Conv-BN-Pool-Dropout y cabeza densa con BN y Dropout.	28
4.4	Matrices de confusión normalizadas (%) en <i>test</i> para la tarea T0 (KL 0-4). Las filas están normalizadas (suman 100 %). Se observa el patrón común de confusión entre grados contiguos (KL1↔KL2, KL2↔KL3) y una identificación más fiable de los extremos (KL0 y KL4), que mejora con la capacidad del modelo y con la transferencia.	33

5.1	Esquema genérico de ViT: particionado en parches 16×16 , proyección a <i>tokens</i> , embeddings posicionales y bloques Transformer con autoatención. La cabeza se ajusta a clasificación KL 0–4 o a regresión en $[0, 4]$	38
5.2	Matriz de confusión normalizada (%) en test para la tarea T0 (KL 0–4) con ViT-B/16 (google/vit-base-patch16-224).	39
6.1	Matrices de confusión para ViT en la Tarea 0–4 (Indirecto, Directo y Fine-tuning).	43
6.2	Matrices de confusión para EfficientNetB0 en la Tarea 0–4 (Indirecto, Directo y Finetuning).	43
6.3	Matrices de confusión para ViT en la Tarea 0–4 (Indirecto, Directo y Fine-tuning).	44
6.4	Matrices de confusión para EfficientNetB0 en la Tarea 0–4 (Indirecto, Directo y Finetuning).	44
6.5	Visualizaciones Grad-CAM para ViT en tres regímenes de entrenamiento.	45
6.6	Visualizaciones Grad-CAM para EfficientNetB0 en tres regímenes de entrenamiento.	45

Índice de tablas

3.1	Distribución de imágenes por partición en la versión curada del OAI	17
3.2	Distribución de clases (KL 0-4) en el conjunto de entrenamiento	18
3.3	Distribución de clases en el conjunto de radiografías felinas (nivel imagen).	19
3.4	Distribución de pacientes únicos por clase en el dataset de gatos.	19
3.5	Comparativa de tareas y resultados en el dataset OAI	21
4.1	Baselines ingenuos por tarea en test (prediciendo siempre la clase mayoritaria).	29
4.2	Resultados Simple CNN en clasificación y regresión	30
4.3	Resultados CNN mediana en clasificación y regresión	30
4.4	Resultados CNN grande en clasificación y regresión	31
4.5	Resultados EfficientNetB0 en clasificación y regresión	31
4.6	Resultados ResNet152 en clasificación y regresión	31
4.7	Resumen por arquitectura en test: exactitud en KL 0–4 y 0-3-4, exactitud en pares binarios (frente a 0) y MAE en regresión.	32
5.1	Especificaciones estructurales (224×224 , parche 16). Parámetros aproximados para referencia.	38
5.2	Resultados de ViT-B/16 (google/vit-base-patch16-224) en test.	38
5.3	Resultados de ViT-B/16 (google/vit-base-patch16-224) en test.	39
5.4	Comparativa resumida en test: Transformers vs. mejores CNN (valores de CNN tomados del capítulo anterior). El resultado de ViT-L/16 en 0–4 corresponde a la formulación de regresión.	39
6.1	Resultados de la Tarea 0–4 para ViT y EfficientNetB0 con distintos tipos de entrenamiento	42

6.2	REGRESSION - Resultados de la Tarea 0–4 para ViT y EfficientNetB0 con distintos tipos de entrenamiento	43
6.3	Resultados de la Tarea 01vs234 para ViT y EfficientNetB0 con distintos tipos de entrenamiento	44

CAPÍTULO 1

Introducción

La artrosis de rodilla es un problema de gran impacto clínico por su prevalencia y por la carga de discapacidad asociada. Su evaluación en radiografías sigue dependiendo, en gran medida, de la experiencia del profesional, lo que introduce variabilidad y dificulta la estandarización. En paralelo, el aprendizaje profundo ha demostrado capacidad para extraer patrones visuales sutiles y apoyar decisiones diagnósticas de forma consistente. Este TFG aborda la **clasificación automática del grado Kellgren–Lawrence (KL)** en radiografías de rodilla y estudia la **transferencia** de modelos entrenados en humanos hacia radiografías felinas, un contexto donde los datos son escasos. El trabajo se centra en *clasificación* sobre recortes ya localizados (no se aborda la detección de la articulación) y compara enfoques con *CNN* y *Transformers* bajo un protocolo unificado. A continuación se detallan la motivación, los objetivos **y la metodología**, y se describe la estructura de la memoria.

1.1 Motivación

Desde el inicio de mi formación académica he mostrado un especial interés por la aplicación de herramientas informáticas en el ámbito de la salud. Este interés se ha visto reforzado por mi entorno familiar, que me ha permitido estar en contacto con problemáticas relacionadas con el diagnóstico y tratamiento de enfermedades en animales. Además, la idea de este trabajo surgió a raíz de una compañera de trabajo de mi padre, quien tenía previsto realizar su tesis doctoral sobre la aplicación de IA en el diagnóstico veterinario. Este hecho me inspiró a explorar cómo las técnicas modernas de aprendizaje profundo, ampliamente utilizadas en medicina humana, podrían adaptarse también al ámbito veterinario.

Desde un principio tenía claro que el tema de mi Trabajo de Fin de Grado estaría relacionado con el aprendizaje automático. La oportunidad de vincularlo con el diagnóstico veterinario, pese a los retos añadidos por la limitación de datos disponibles, me llevó a elegir esta temática como base de mi investigación.

La artrosis (u osteoartritis) es una de las enfermedades musculoesqueléticas más comunes a nivel mundial y una de las principales causas de discapacidad en adultos mayores. Su diagnóstico y seguimiento dependen habitualmente de la evaluación clínica y de la interpretación de imágenes médicas (radiografías, resonancias magnéticas o tomografías), un proceso sujeto a la experiencia del profesional y que puede presentar variabilidad entre observadores. En los últimos años, los avances en IA, y en particular en el aprendizaje profundo (*deep learning*), han demostrado un gran potencial para mejorar la precisión y la eficiencia en el análisis de imágenes médicas. Las redes neuronales convolucionales (CNN) y, más recientemente, los modelos basados en *Transformers*, han

mostrado resultados prometedores en este ámbito, como evidencian recientes trabajos que emplean conjuntos de datos biomédicos como MedMNIST.

Este TFG se motiva por la necesidad de desarrollar métodos automáticos y robustos para el análisis de la artrosis mediante técnicas de aprendizaje profundo, evaluando tanto arquitecturas convolucionales como modelos *Transformer*. Un aspecto innovador de este trabajo es la exploración del *transfer learning* entre dominios anatómicos distintos, utilizando modelos entrenados en radiografías de rodillas humanas para aplicarlos también al diagnóstico en gatos. Esta línea de investigación podría beneficiar la práctica veterinaria, donde la disponibilidad de datos suele ser más limitada.

La relevancia de este estudio radica en su potencial impacto en la práctica clínica y veterinaria, al reducir la carga de trabajo de los especialistas, mejorar la objetividad del diagnóstico y ofrecer herramientas de soporte a la decisión clínica. Además, a nivel formativo, este proyecto me permite adquirir experiencia en técnicas avanzadas de visión por computador, gestión de conjuntos de datos biomédicos, entrenamiento de redes neuronales profundas y análisis de resultados, competencias clave para mi futuro profesional en el ámbito de la IA aplicada a la salud.

1.2 Objetivos del TFG

El propósito de este TFG es diseñar, implementar y validar un sistema de clasificación automática de artrosis de rodilla en radiografías, maximizando su utilidad clínica y su capacidad de generalización, incluso en contextos veterinarios con datos limitados. Para ello, se plantean los siguientes objetivos concretos y medibles:

1. **Desarrollar y comparar modelos de aprendizaje profundo** (CNN desde cero, modelos preentrenados y Transformers de visión) para la clasificación KL 0–4 y tareas binarias en OAI, *evaluando* su rendimiento bajo un protocolo unificado con *accuracy*, *macro-F1* y *MAE*, y *reportando*.
2. **Evaluar la transferencia interdominio humano→felino** comparando inferencia directa, entrenamiento desde cero y *fine-tuning* a partir de pesos en OAI, *cuantificando* diferencias de rendimiento entre los tipos de entrenamiento y los resultados utilizando el dataset OAI.



Estructura de la memoria

Este Trabajo Fin de Grado estudia la clasificación automática de artrosis de rodilla mediante aprendizaje profundo y su transferencia a radiografías felinas. La memoria se organiza del siguiente modo. **En Preliminares** se introducen los conceptos esenciales de aprendizaje automático y redes neuronales, así como su evolución reciente en visión por computador con ejemplos de conjuntos públicos biomédicos. El **Capítulo 3** describe los datos utilizados —el *dataset* OAI y el conjunto externo de radiografías felinas—, sus particiones y desbalance, y define las tareas de clasificación que se abordarán, situando el trabajo en su contexto. El **Capítulo 4** presenta los experimentos con *redes convolucionales*, incluyendo modelos desde cero y modelos preentrenados, bajo una configuración de entrenamiento unificada y con comparación de resultados. El **Capítulo 5** incorpora *Transformers* de visión, su adaptación a la tarea y su evaluación con el mismo protocolo. El **Capítulo 6** analiza la transferencia interdominio hacia radiografías felinas, comparando inferencia directa, entrenamiento específico y ajuste fino, y discutiendo su utilidad

clínica. En **Conclusiones** se sintetizan los hallazgos, se verifica el grado de cumplimiento de los objetivos y se proponen líneas futuras. La **Bibliografía** recoge las referencias empleadas. Los **Apéndices** incluyen la configuración del sistema (entorno, dependencias y parámetros de reproducción), tablas y métricas ampliadas y detalles de preprocesado. **Dado que el tribunal puede ser interdisciplinar, al final** se incorpora un **glosario de términos** técnicos para consulta.

CAPÍTULO 2

Preliminares

2.1 Aprendizaje automático

El **aprendizaje automático** (ML) es una rama de la inteligencia artificial cuyo objetivo es que los sistemas mejoren su desempeño en una tarea a partir de la experiencia, en la línea de la definición clásica de Mitchell: “un programa aprende de la experiencia E con respecto a una clase de tareas T y una medida de rendimiento P si su rendimiento en tareas de T , medido por P , mejora con la experiencia E ” [14]. En términos prácticos, esto implica diseñar algoritmos capaces de *generalizar* patrones desde datos observados a datos no vistos, evitando depender de reglas fijas. Habitualmente se representan los datos mediante *características* (features) y se induce un modelo f_θ que relaciona entradas x con salidas y bajo una función objetivo o *pérdida* $\mathcal{L}$ [2, 8]. Un objetivo central es equilibrar el *ajuste* a los datos de entrenamiento con la *capacidad de generalización*, mitigando el *sobreajuste* (overfitting) y el *subajuste* (underfitting). La Figura 2.1 ilustra visualmente estas situaciones, fundamentales para entender el rendimiento de los modelos.




Figura 2.1: Ejemplo ilustrativo de subajuste, buen ajuste y sobreajuste en un modelo supervisado. Adaptado de [1].

Paradigmas de aprendizaje. Según cómo se proporcionen las señales a aprender, distinguimos tres familias principales [2, 8]:

- **Aprendizaje supervisado.** Se dispone de pares (x, y) con etiqueta “verdadera”. El objetivo es aprender una función $f_\theta : x \mapsto y$. Son tareas típicas la *clasificación* (p. ej., predecir un grado de severidad KL) y la *regresión* (p. ej., predecir una puntuación continua de severidad). En clasificación se usa habitualmente entropía cruzada; en regresión, error cuadrático medio (MSE). En entornos clínicos es frecuente ajustar pesos por clase o emplear pérdidas robustas para combatir el *desbalance* [2].

- **Aprendizaje no supervisado.** No hay etiquetas: el algoritmo descubre estructura (p. ej., *clustering*, *reducción de dimensionalidad*). Es útil para exploración de datos, detección de outliers o preentrenamiento de representaciones [2].
- **Aprendizaje por refuerzo.** Un *agente* interactúa con un entorno y aprende una *política* que maximiza la recompensa acumulada. Es más relevante en control y toma de decisiones secuenciales que en **esta memoria** [8].

Entrenamiento y optimización. En aprendizaje supervisado se ajustan los parámetros θ minimizando una pérdida empírica $\frac{1}{N} \sum_{i=1}^N \mathcal{L}(f_{\theta}(x_i), y_i)$ mediante *descenso de gradiente* y variantes estocásticas/minibatch (SGD), muy eficientes para grandes volúmenes de datos [8]. En cada iteración se calcula el gradiente $\nabla_{\theta} \mathcal{L}$ y se actualiza $\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$, donde η es la tasa de aprendizaje. Optimizadores basados en momentos (p. ej., Adam) aceleran la convergencia ajustando adaptativamente los pasos [8]. Además, se emplean *regularizadores* (p. ej., L2), *dropout* y *early stopping* para mejorar la generalización [8]. La Figura 2.2 resume el flujo de optimización.




Figura 2.2: Flujo de entrenamiento de un modelo supervisado mediante descenso de gradiente. Adaptado de [13].

Procedimiento típico de entrenamiento. El siguiente pseudocódigo sintetiza un bucle de entrenamiento con minibatches y early stopping:

Require: Conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^N$, validación $\{(x_j^{(v)}, y_j^{(v)})\}$, tasa de aprendizaje η , pérdida $\mathcal{L}$, paciencia p
 Inicializar θ y el mejor valor de validación $V^* \leftarrow +\infty$, contador $c \leftarrow 0$
for épocas **do**
 for cada minibatch B **do**
 $\hat{y} \leftarrow f_{\theta}(B)$; $L \leftarrow \mathcal{L}(\hat{y}, y)$
 $g \leftarrow \nabla_{\theta} L$; $\theta \leftarrow \theta - \eta \cdot g$
 end for
 Calcular pérdida/métricas en validación V
 if $V < V^*$ **then**
 $V^* \leftarrow V$; $c \leftarrow 0$; **guardar** θ
 else
 $c \leftarrow c + 1$;
 if $c \geq p$ **then**
 parar (early stopping)

```

end if
end if
end for

```

Validación y estimación honesta del desempeño. Para estimar la generalización es clave separar datos en *entrenamiento*, *validación* (para seleccionar hiperparámetros) y *prueba* (sólo para la evaluación final). Alternativamente, se usa *validación cruzada* (p. ej., *k-fold*) cuando los datos son escasos. Es esencial evitar *fugas de información* (data leakage), aplicar el mismo preprocesado a todas las particiones y no “mirar” el conjunto de prueba durante el desarrollo [2]. En problemas clínicos, además de *accuracy*, son relevantes métricas por clase (F1 macro), AUC/ROC, sensibilidad/especificidad y, cuando procede, análisis de *calibración* probabilística [2].

Sesgos, varianza y desbalance. El *compromiso sesgo-varianza* explica por qué modelos muy simples subajustan (alto sesgo) y modelos excesivamente complejos sobreajustan (alta varianza). La regularización, el aumento de datos y una adecuada complejidad del modelo ayudan a situarse en el punto intermedio [2]. Cuando existe *desbalance de clases*—común en severidades avanzadas (KL3-KL4)—, pueden usarse estrategias como *class weights*, remuestreo estratificado o métricas macro-promediadas para evitar que la clase mayoritaria domine el entrenamiento [2]. En entornos biomédicos es especialmente importante reportar resultados por clase y analizar matrices de confusión.




Figura 2.3: Ilustración del compromiso sesgo-varianza: relación entre la complejidad del modelo y el error de entrenamiento y validación. [7]

Modelos clásicos y aprendizaje profundo. Algoritmos como árboles de decisión, SVM o *k*-NN resuelven correctamente múltiples problemas con pocas muestras y *features* diseñadas a mano [2]. Sin embargo, en visión por computador las **redes neuronales profundas** (DNN)—especialmente las *convolucionales* (CNN) y, más recientemente, los *Transformers*— aprenden jerarquías de características directamente de las imágenes, consiguiendo rendimientos superiores cuando hay datos y cómputo suficientes [8]. Hitos como el perceptrón [16], la *retropropagación* [17], *AlexNet* [10] y las conexiones residuales en *ResNet* [9] marcaron la evolución reciente del campo.

Buenas prácticas aplicadas en este TFG (conexión con el dominio clínico). En esta memoria se sigue un protocolo que refleja las recomendaciones anteriores: (i) formulación explícita del problema (KL 0–4 multiclase y variantes binarias/ordinales); (ii) particionado estratificado y uso consistente de un *set* de validación para *early stopping* y *schedulers*; (iii) pérdidas acordes a la tarea (entropía cruzada y MSE para formulaciones ordinales);

(iv) *data augmentation* realista (rotaciones, volteos, brillo/contraste) para robustez; (v) métricas complementarias (accuracy, F1 macro, MAE) y análisis por clase; y (vi) verificación cualitativa con *Grad-CAM* para inspeccionar que las regiones activadas sean anatómicamente plausibles. Este enfoque busca maximizar la validez clínica del resultado, reduciendo riesgos de sobreajuste y sesgos.

Resumen. El aprendizaje automático proporciona el armazón metodológico para extraer conocimiento de datos y construir predictores con capacidad de generalización. La correcta elección de la formulación (clasificación vs. regresión/ordinal), pérdidas, métricas y protocolo de validación, junto con regularización y análisis de interpretabilidad, es crucial en aplicaciones clínicas. Estas ideas se aplican y amplían en las secciones posteriores con redes profundas específicas de visión y con experimentos sobre OAI y validación interdominio.

2.2 Redes Neuronales

Las **redes neuronales artificiales** (RNA) constituyen una familia de modelos de aprendizaje automático inspirados —de forma muy abstracta— en el procesamiento de información del cerebro. La unidad básica es la *neurona artificial*, que calcula una combinación lineal de sus entradas seguida de una no linealidad o *función de activación*. Si una neurona recibe $x_1, \dots, x_n$ con pesos $w_1, \dots, w_n$ y sesgo b , su salida es

$$y = \sigma \left(\sum_{i=1}^n w_i x_i + b \right),$$

donde $\sigma(\cdot)$ puede ser sigmoide, tangente hiperbólica o ReLU. El *Perceptrón* de Rosenblatt [16] es el antecedente histórico más conocido: una arquitectura de una sola capa capaz de resolver problemas linealmente separables pero limitada para funciones como XOR (limitación que impulsó la búsqueda de arquitecturas más expresivas).

La potencia de las RNA surge al componer neuronas en **arquitecturas multicapa** o *perceptrones multicapa* (MLP), organizadas en capas de entrada, varias *capas ocultas* y una capa de salida. La presencia de activaciones no lineales permite aproximar funciones altamente no lineales; de hecho, bajo hipótesis suaves, los MLP actúan como *aproximadores universales* [2, 8]. En la Figura 2.4 se ilustra esquemáticamente una red profunda.




Figura 2.4: Ejemplo de una red neuronal profunda [neural_network]

El entrenamiento efectivo de redes multicapa se basa en la *retropropagación del error* (*backpropagation*), que aplica la regla de la cadena para calcular derivadas parciales de la pérdida respecto a cada parámetro, combinada con descenso de gradiente y sus variantes estocásticas/minibatch [17, 8]. En cada iteración se realiza una *fase forward* para obtener

predicciones y una *fase backward* para propagar gradientes y actualizar pesos. Este marco permitió escalar el aprendizaje a redes con millones de parámetros. La disponibilidad de grandes conjuntos de datos y el cómputo en GPU —popularizado en visión con *AlexNet*— catalizó el auge del **aprendizaje profundo** [10, 8].

Un hito simbólico fue ImageNet 2012: *AlexNet* introdujo redes convolucionales profundas entrenadas en GPU y regularización con *dropout*, logrando una mejora drástica en clasificación a gran escala [10]. A partir de ahí aparecieron arquitecturas más profundas (VGG) y eficientes (Inception), hasta las **redes residuales** (*ResNet*) que incorporan *skip connections* para mitigar el desvanecimiento del gradiente y permitir el entrenamiento de redes muy profundas con excelente precisión [9]. Estos avances —junto con técnicas de normalización, inicialización y optimización modernas— cimentan el estado del arte actual [8].

Una clase clave para datos con estructura espacial/temporal son las **redes neuronales convolucionales** (CNN). A diferencia de un MLP denso, las CNN emplean *filtros* que se comparten espacialmente y operan sobre *campos receptivos* locales, explotando la *estacionaridad* de las imágenes y reduciendo drásticamente el número de parámetros. Típicamente se intercalan capas de *pooling* (o estrategias equivalentes de reducción espacial) que aportan invarianza traslacional y control de complejidad [8]. Una arquitectura de clasificación suele apilar varios bloques conv → no linealidad → reducción espacial, seguidos de un *cabecal* de clasificación. La Figura 2.5 muestra un esquema simplificado.




Figura 2.5: Ejemplo de arquitectura de una red neuronal convolucional para clasificación de imágenes. Se observan capas convolucionales (conv) que aplican filtros aprendibles sobre la imagen de entrada, seguidas de capas de pooling que reducen la resolución. Al final, capas totalmente conectadas (FC) procesan las características extraídas para producir la clasificación en alguna de las categorías.

En visión por computador, las CNN han sustituido con éxito a *pipelines* de *features* manuales al aprender representaciones jerárquicas directamente de los datos [8]. En imagen médica, esta capacidad resulta especialmente valiosa para detectar patrones sutiles en radiografías, resonancias o microscopías que son difíciles de describir manualmente. No obstante, su entrenamiento robusto exige datos anotados y protocolos de validación cuidadosos. Cuando los datos son limitados —situación habitual en el ámbito clínico— es común aplicar **aprendizaje por transferencia**: inicializar con pesos preentrenados en dominios amplios (p. ej., ImageNet) y afinar (*fine-tuning*) para la tarea específica, aprovechando la transferibilidad de filtros de bajo/medio nivel [8].

Transformers en visión (visión global frente a sesgo local). Más recientemente, los **Transformers** han demostrado gran rendimiento en visión por computador al reemplazar los filtros locales por *autoatención* que modela dependencias de largo alcance. *Vision Trans-*

former (ViT) divide la imagen en parches (p. ej., 16×16), los proyecta a *embeddings*, añade codificación posicional y procesa la secuencia mediante bloques de atención con un *class token* para la predicción [6]. Este enfoque tiene *menor sesgo inductivo local* que una CNN —no impone de inicio la vecindad espacial— y, a cambio, suele requerir más datos o regularización para generalizar; su ventaja es capturar *contexto global* desde capas tempranas. Para entornos con menos datos, **DeiT** introduce estrategias de entrenamiento data-efficient y destilación para obtener Transformers competitivos sin preentrenamientos masivos [18]. Por su parte, **Swin Transformer** propone una atención *jerárquica* basada en *ventanas deslizantes* que preserva inductivos locales y escala eficientemente a alta resolución [12]. En el contexto de este TFG (gradación KL), la capacidad de integrar señales *globales* (p. ej., relación tibiofemoral, distribución del estrechamiento del espacio articular) puede complementar el sesgo local de las CNN; en datasets clínicos moderados, el *preentrenamiento* y un *fine-tuning* cuidadoso son determinantes. Un esquema de este *pipeline* se muestra en la Fig. 2.6.

Para cerrar esta sección, la Fig. 2.6 resume visualmente el flujo de ViT descrito, desde la división en parches hasta la predicción mediante el *class token*.




Figura 2.6: Esquema de Vision Transformer (ViT): la imagen se divide en parches que se proyectan a embeddings, se añade codificación posicional y se procesan mediante bloques de autoatención. Un token especial de clase (*class token*) permite la clasificación final, aprovechando el mecanismo de atención para capturar relaciones globales entre todas las regiones de la imagen. [5]

Interpretabilidad. Aunque la atención facilita inspecciones cualitativas, *atención* $\neq$ *explicación* de forma estricta. Existen técnicas específicas para analizar Transformers en visión (p. ej., *attention rollout*, relevancias derivadas de gradientes) que permiten obtener mapas compatibles con los usados en CNN; en este TFG se emplean mapas tipo Grad-CAM/rollout como control cualitativo adicional, sin considerarlos evidencia clínica por sí misma [3].

Resumen y conexión con los experimentos. Las redes neuronales —y en particular las CNN profundas y los Transformers— constituyen la base del estado del arte en reconocimiento de patrones e imagen médica: retropropagación [17], cómputo en GPU [10] y conexiones residuales [9] han permitido escalar su profundidad y precisión, mientras que la autoatención aporta alcance *global* [6, 18, 12]. En los capítulos siguientes se aplican

estas familias a la clasificación de artrosis en rodillas, comparando su rendimiento bajo un protocolo unificado y verificando plausibilidad anatómica con mapas de activación.

2.3 Aprendizaje automático en imágenes médicas


El **aprendizaje automático en imágenes médicas** (*medical imaging*) comparte los principios de la visión por computador general, pero introduce particularidades técnicas y clínicas que condicionan tanto el *tratamiento de datos* como el *diseño y la validación* de los modelos. A diferencia de las imágenes naturales, las imágenes clínicas se adquieren bajo *protocolos estandarizados* y se codifican con *metadatos* (p. ej., formato DICOM). Existen distintas modalidades de imagen médica, destacando la *radiografía* por su amplia disponibilidad. Además, los objetivos habituales van más allá de la simple *clasificación*: incluyen **detección**, **segmentación**, **estimación ordinal de severidad**, **calibración de riesgo** y **pronóstico**. Esta diversidad de tareas, unida a la *escasez de datos anotados por expertos* y a la *crítica de los diagnósticos*, explica por qué es uno de los ámbitos donde más está costando integrar redes neuronales de forma segura y robusta [11].

Pipeline típico de trabajo. Un flujo estándar comprende: (1) *adquisición y curación* (lectura DICOM/PNG, verificación de metadatos); (2) *preprocesado* específico por modalidad (p. ej., normalización de intensidades, mejora de contraste); (3) *homogeneización geométrica* (recortes centrados, reescalado, estandarización de orientación); (4) *aumento de datos* con transformaciones geométricas y de intensidad *con conocimiento del dominio*; (5) *entrenamiento del modelo* con particiones *train/val/test* sin contaminación por paciente ni temporal; (6) *validación interna* y, cuando sea posible, **validación externa** (centros distintos o cohortes temporales) para medir robustez [11]; (7) análisis de *calibración*, *curvas ROC/PR* y *sensibilidad/especificidad*; (8) **interpretabilidad** (p. ej., Grad-CAM) y revisión clínica [selvaraju2017grad].

Modelos: de CNN a arquitecturas modernas Las **CNN profundas** han sido el estándar en visión por computador durante la última década por su capacidad de extraer *patrones jerárquicos* y aprovechar *aprendizaje por transferencia*. Más recientemente, arquitecturas basadas en *mecanismos de atención*, en particular los *Vision Transformers*, han ganado tracción y se han aplicado con éxito a tareas de clasificación de imágenes a gran escala [dosovitskiy2021an]; parte de este trabajo incluye replicar experimentos utilizando dichos modelos.

Evidencia de rendimiento y adopción clínica Revisiones sistemáticas y metaanálisis han comparado el rendimiento del *deep learning* con profesionales sanitarios en distintas tareas de imagen; por ejemplo, [11] reporta que, en varios escenarios, los modelos alcanzan desempeños comparables en sensibilidad/especificidad, subrayando la **importancia de la validación externa** y la **calidad metodológica** de los estudios.

Caso de estudio frecuente: rodilla y artrosis La articulación de la rodilla es un ejemplo clásico por la prevalencia de la osteoartritis y la existencia de **cohortes longitudinales** de acceso público. Sobre esta base, existen colecciones curadas de radiografías anotadas con escalas como *Kellgren–Lawrence* y trabajos que combinan *detección de la articulación* con clasificación o graduación (incluyendo formulaciones ordinales). Estos recursos han facilitado la comparación de arquitecturas (VGG/ResNet/EfficientNet/ViT) y de formulaciones (multiclase vs. ordinal) en entornos reproducibles.




(a) KL 0

Particularidades del preprocesado en radiografías En radiografía simple, el contraste depende de factores como kilovoltaje, filtrado y grosor del paciente. Es habitual normalizar intensidades, ajustar el rango dinámico y, para modelos centrados en una articulación concreta, **recortar la ROI** con detectores o heurísticas anatómicas. Estas operaciones reducen la variación intercentro y ayudan a que el modelo se enfoque en *pistas radiográficas* relevantes (osteofitos, esclerosis subcondral, pinzamiento del espacio articular, etc.).

Métricas y análisis estadístico En *clasificación* multiclase se reportan *accuracy*, *F1 macro* y *matrices de confusión* por clase; en *binaria* es común AUC-ROC/PR junto a sensibilidad/especificidad para umbrales clínicos. En formulaciones **ordinales/regresivas** se incluye el MAE y estadísticos de calibración (*reliability diagrams*). La **validación externa** en centros distintos y la evaluación por subgrupos (edad, sexo, dispositivo) son claves para estimar *generalización* y *equidad* [11]. También resulta recomendable contrastar el acuerdo con expertos mediante coeficientes tipo *Cohen / Fleiss kappa* cuando proceda.

Interpretabilidad y verificación clínica. La *explicabilidad* busca comprobar que el modelo basa sus decisiones en regiones anatómicas coherentes. Mapas de activación como *Grad-CAM* permiten superponer *heatmaps* sobre la imagen original, ayudando a detectar atajos espurios (p. ej., artefactos o marcas de la placa) y a construir confianza clínica [selvaraju2017grad]. Aunque la explicabilidad no sustituye a una validación externa, sí que es útil como validación adicional.



(a) KL 0

(b) KL 1

Retos recurrentes Entre los desafíos más citados se encuentran: (i) **desbalance de clases** (p. ej., escasez de grados severos), lo que exige atención a la precisión por clase y a contextualizar la métrica global; (ii) **cambio de dominio** entre centros, equipos y protocolo (*domain shift*); (iii) **ruido de etiqueta** e **incertidumbre** interobservador; (iv) **tamaño de los datos** limitado; (v) **calibración** deficiente; (vi) **reproducibilidad** (documentación de versiones, semillas, *splits*) y **privacidad**; y (vii) **requisitos regulatorios**. La literatura

recomienda predefinir protocolos de validación, fijar semillas, conservar *splits* oficiales cuando existan y acompañar los resultados de *intervalos de confianza* [11].

Síntesis El uso de aprendizaje profundo en imagen médica ha pasado de estudios de laboratorio a validaciones multicéntricas y primeros productos comerciales. Las CNN profundas y las pérdidas adaptadas a ordinalidad han demostrado utilidad en problemas como la *artrosis de rodilla* (cohortes OAI) [15, 4], mientras que la evidencia comparativa con profesionales sugiere viabilidad siempre que existan *pipelines* de validación y control de calidad robustos [11]. De cara a su adopción, la **calibración**, la **generalización** y la **explicabilidad** son tan relevantes como la métrica primaria.

CAPÍTULO 3

Descripción de los datasets y tareas comunes

3.1 Introducción

En el contexto del aprendizaje profundo aplicado a la visión por ordenador, la adecuada selección y descripción de los conjuntos de datos constituye un pilar esencial para garantizar la robustez, validez y reproducibilidad de los experimentos. En este capítulo se presentan, con un enfoque exhaustivo y comparativo, los dos principales recursos que sustentan el presente Trabajo de Fin de Grado: el *dataset* OAI, ampliamente reconocido en el ámbito de la medicina humana, y un *dataset* privado de radiografías de gatos, recopilado en un entorno veterinario. Ambos datasets, a pesar de sus diferencias en escala, contexto y especie, convergen en un objetivo común: la clasificación de la artrosis mediante técnicas de inteligencia artificial.

La inclusión de estos dos dominios diferenciados —humano y felino— permite no solo ilustrar la versatilidad de las arquitecturas de aprendizaje profundo, sino también explorar de manera empírica la transferencia de conocimiento entre especies anatómicamente distintas. Este enfoque inter-específico amplía el alcance del estudio, facilitando una evaluación rigurosa de la capacidad de generalización de los modelos propuestos y proporcionando un marco idóneo para examinar el impacto del dominio sobre el rendimiento de los clasificadores.

El *Osteoarthritis Initiative* (OAI) es un estudio longitudinal y multicéntrico iniciado por los NIH, diseñado para capturar la progresión de la artrosis de rodilla a lo largo de más de una década. Este dataset proporciona no solo una gran variedad de imágenes radiográficas etiquetadas mediante la escala **Kellgren-Lawrence (KL)**, sino también una rica colección de metadatos clínicos, demográficos y de seguimiento longitudinal. A lo largo de los años, su versión procesada ha sido objeto de numerosos estudios científicos, consolidándose como referencia obligada en el campo. Su estructura curada, resoluciones estándar y disponibilidad pública hacen de él una herramienta metodológicamente sólida para el entrenamiento y evaluación de modelos supervisados. Se recomienda al lector consultar la Figura 3.1 para una visualización representativa de los grados KL.

Por otro lado, el *dataset* veterinario, aunque de escala considerablemente menor y de acceso restringido, ofrece una oportunidad única para validar externamente los modelos desarrollados. Este conjunto de imágenes felinas, anotadas también según la escala KL, permite evaluar la capacidad de los clasificadores para adaptarse a cambios morfológicos y de contexto clínico. Su utilidad no radica tanto en la comparación cuantitativa, sino en

su valor como escenario de *domain adaptation*, abriendo la puerta a nuevas preguntas sobre la transferibilidad de características aprendidas.

Ambos conjuntos de datos utilizan la escala ordinal de Kellgren-Lawrence, compuesta por cinco grados de severidad (del 0 al 4), que permiten estandarizar la anotación y facilitar la formulación de tareas tanto de clasificación como de regresión. A continuación, se enumeran los grados según su descripción radiográfica, lo cual se refleja visualmente en la Figura 3.1:

- **Grado 0:** Ausencia de signos radiográficos de artrosis.
- **Grado 1:** Muy leve; posible pinzamiento articular mínimo o presencia incipiente de osteofitos marginales.
- **Grado 2:** Leve; osteofitos evidentes y estrechamiento leve del espacio articular.
- **Grado 3:** Moderado; múltiples osteofitos medianos, pinzamiento definido y esclerosis subcondral leve.
- **Grado 4:** Severo; osteofitos grandes, pérdida significativa del espacio articular, esclerosis marcada y deformidad ósea visible.

Esta categorización ordinal constituye una referencia clínica ampliamente aceptada, aunque no exenta de subjetividad interobservador, lo que refuerza la necesidad de sistemas automáticos de ayuda al diagnóstico.

A nivel metodológico, este capítulo se estructura en cinco secciones interconectadas. En la Sección 3.2 se detalla la composición y características del *dataset* OAI, incluyendo sus particiones, resoluciones y distribución de clases. La Sección 3.3 presenta el *dataset* veterinario, detallando el proceso de recolección, anotación y sus particularidades. En la Sección 3.4, se abordan las tareas habituales de clasificación (binaria, multiclase y ordinal), junto con aspectos relevantes como el desbalance de clases, técnicas de preprocesamiento y métricas de evaluación. Finalmente, la Sección 3.5 resume los principales hallazgos del capítulo, sentando las bases para el diseño experimental que se desarrollará en los capítulos siguientes.

Con este recorrido, se pretende ofrecer una visión integrada y coherente de los recursos de datos utilizados, así como de las tareas computacionales implicadas, garantizando la transparencia, reproducibilidad y rigor científico del presente Trabajo de Fin de Grado.

3.2 Dataset OAI

La *Osteoarthritis Initiative (OAI)* es un estudio observacional, multicéntrico y longitudinal iniciado en 2004 por los *National Institutes of Health (NIH)* de Estados Unidos. Su objetivo principal ha sido identificar y validar biomarcadores asociados a la aparición y progresión de la artrosis de rodilla sintomática. Con más de una década de seguimiento, este recurso se ha consolidado como un estándar en la investigación clínica, al proporcionar no solo radiografías de rodilla, sino también metadatos clínicos, demográficos y muestras biológicas. En este trabajo se emplean exclusivamente las radiografías, si bien resulta relevante destacar la riqueza multimodal del estudio.

Para facilitar su aplicación en tareas de aprendizaje automático, se emplea la versión procesada del OAI publicada en Mendeley Data y Kaggle por Chen et al. [4]. Este conjunto consta de **9 786 radiografías de rodilla** recortadas y normalizadas, anotadas con grados de severidad según la escala de Kellgren–Lawrence (KL), que varía entre 0 (ausencia de

artrosis) y 4 (artrosis severa). En Mendeley Data las imágenes se encuentran disponibles en resoluciones de **224x224** y **299x299** píxeles, mientras que en Kaggle solo se ofrece la versión de 224x224, optimizada para arquitecturas convolucionales como ResNet, VGG o EfficientNet.

La Figura 3.1 muestra ejemplos representativos de radiografías para cada grado KL. Aunque esta escala es el estándar más utilizado en la literatura, presenta limitaciones bien documentadas, como la subjetividad en la interpretación y la variabilidad entre observadores, lo que ha motivado la búsqueda de enfoques automáticos más consistentes y reproducibles en la evaluación de la artrosis.




Figura 3.1: Ejemplos de radiografías de rodilla correspondientes a los cinco grados de la escala Kellgren-Lawrence (KL).

Las características principales de esta versión procesada, ampliamente utilizada en la comunidad científica, se resumen a continuación:

- **Número de imágenes y particiones:** El dataset contiene un total de **9 786 radiografías**, distribuidas en cuatro subconjuntos: *train* (5 778), *validation* (826), *test* (1 656) y *auto_test* (1 526), como se detalla en la Tabla 3.1.


Tabla 3.1: Distribución de imágenes por partición en la versión curada del OAI

Partición	Número de imágenes	Porcentaje
Entrenamiento (Train)	5 778	59.0 %
Validación (Validation)	826	8.4 %
Prueba (Test)	1 656	16.9 %
Autoevaluación (AutoTest)	1 526	15.6 %

- **Etiquetas:** Cada radiografía está clasificada con un grado KL (0-4) asignado por radiólogos expertos de la OAI, lo que posibilita la formulación de tareas de clasificación supervisada.
- **Resolución y preprocesamiento:** Las imágenes han sido recortadas a la región de la rodilla y normalizadas. Están disponibles en resoluciones de 224x224 y 299x299 píxeles, lo que facilita su integración en arquitecturas CNN preentrenadas.
- **Distribución de clases:** El conjunto presenta un marcado desbalance hacia las categorías más leves de artrosis. La Tabla 3.2 muestra la distribución en el subconjunto de entrenamiento, mientras que la Figura 3.2 resume la proporción relativa de cada grado KL en los tres *splits* principales (entrenamiento, validación y prueba).

Tabla 3.2: Distribución de clases (KL 0-4) en el conjunto de entrenamiento

Clase KL	Número de imágenes	Porcentaje
0 (Sin artrosis)	2 286	40 %
1 (Ligera)	1 046	18 %
2 (Leve)	1 516	26 %
3 (Moderada)	757	13 %
4 (Severa)	173	3 %

**Figura 3.2:** Distribución porcentual de las clases KL (0-4) en las particiones de entrenamiento, validación y prueba del dataset OAI. Se observa un predominio de las categorías más leves en *train* y *val*, y una representación mayor de grados avanzados en *test*.

- **Splits y reproducibilidad:** La existencia de particiones predefinidas garantiza la comparabilidad entre estudios y la reproducibilidad de resultados. Considerando únicamente entrenamiento, validación y prueba, se mantiene la proporción estándar de 70 % / 10 % / 20 %, ampliamente adoptada en la comunidad. El subconjunto *auto_test*, aunque no siempre utilizado, puede servir para aumentar la robustez experimental.

En conjunto, el OAI constituye un recurso de referencia tanto por su tamaño como por su relevancia clínica. No obstante, el desbalance de clases y la subjetividad inherente a la escala KL plantean retos adicionales que deben ser abordados en el diseño y la evaluación de los modelos de clasificación.

3.3 Dataset de gatos

El *dataset* de gatos constituye un conjunto de radiografías recopiladas en el marco del proyecto de tesis doctoral de Bea en el [Nombre del Laboratorio/Institución] (TODO: completar referencia en formato APA). A diferencia del *Osteoarthritis Initiative (OAI)*, que es un recurso público de gran escala, este conjunto es de carácter privado y se encuentra restringido a fines de investigación bajo autorización expresa de su autora.

Las imágenes fueron adquiridas mediante procedimientos radiográficos controlados de ejemplares felinos, garantizando un mínimo de dos adquisiciones frontales, una por

rodilla rodilla. El conjunto incluye proyecciones frontales y laterales; sin embargo, para mantener la coherencia metodológica con el dataset OAI y favorecer la comparabilidad de resultados, en este trabajo se emplean únicamente las proyecciones **frontales**, recortadas manualmente a la región de interés (ROI).

En total, se dispone de **82 radiografías correspondientes a 39 gatos únicos**. Cada imagen fue anotada según la **escala de Kellgren–Lawrence (KL)** en cinco categorías ordinales (0–4), adaptadas a la evaluación veterinaria. La Tabla 3.3 presenta la distribución de radiografías por clase, mientras que la Tabla 3.4 recoge la distribución a nivel de pacientes únicos, lo que permite distinguir entre representatividad en número de imágenes y en sujetos.

Tabla 3.3: Distribución de clases en el conjunto de radiografías felinas (nivel imagen).

Clase KL	Imágenes	Porcentaje
KL 0	22	~27 %
KL 1	30	~36 %
KL 2	18	~22 %
KL 3	10	~13 %
KL 4	2	~2 %

Tabla 3.4: Distribución de pacientes únicos por clase en el dataset de gatos.

Clase KL	Pacientes únicos	Porcentaje
0 (Sin artrosis)	11	28 %
1 (Ligera)	15	38 %
2 (Leve)	9	18 %
3 (Moderada)	5	13 %
4 (Severa)	1	3 %

Tal como se aprecia, existe un **desbalance de clases** caracterizado por una mayor presencia de casos en KL 0 y KL 1, y una marcada escasez en la categoría severa (KL 4). Este desbalance reproduce una situación común en datasets médicos y veterinarios, en los que los estadios tempranos de la enfermedad son más prevalentes que los casos avanzados.




Figura 3.3: Distribución porcentual de radiografías felinas según la escala KL. Se observa una clara predominancia de casos sin artrosis o con artrosis ligera.

El conjunto de gatos se empleará en este trabajo como **validación externa** para evaluar la **robustez y capacidad de generalización** de los modelos entrenados sobre OAI (radiografías humanas). De esta forma, se explora cómo responden los clasificadores frente a variaciones anatómicas relevantes y a un *cambio de dominio* real (humano $\rightarrow$ felino) manteniendo la misma tarea ordinal de clasificación.

Adicionalmente, se plantea su uso en experimentos de *fine-tuning*, con dos estrategias complementarias: (i) partir de arquitecturas preentrenadas en repositorios genéricos como ImageNet, y (ii) aprovechar directamente los pesos de modelos entrenados previamente con OAI. En ambos casos, se seguirá un enfoque conservador, congelando las capas iniciales del *backbone* y ajustando únicamente las capas superiores, a fin de mitigar el riesgo de sobreajuste en un dataset de tamaño limitado.

En resumen, aunque reducido y con ciertas limitaciones inherentes (privacidad, desbalance de clases y escasez de ejemplos severos), este dataset representa un recurso relevante para estudiar la **transferencia de conocimiento entre dominios heterogéneos** y evaluar la aplicabilidad práctica de los modelos de visión por computador en contextos más allá del ámbito humano.

3.4 Tareas comunes

El conjunto *Osteoarthritis Initiative* (OAI) se ha convertido en un estándar de facto para entrenar y validar modelos de aprendizaje profundo destinados a estimar la severidad de la artrosis de rodilla. Su valor reside en la combinación de imagen radiográfica homogénea, anotaciones expertas con la escala *Kellgren–Lawrence* (KL) y un tamaño muestral suficiente para comparar arquitecturas y protocolos bajo condiciones reproducibles. En este contexto, la investigación reciente converge hacia un mismo objetivo clínico—caracterizar el estadio de la enfermedad—que, sin embargo, se formula computacionalmente de maneras sutilmente distintas según el propósito del estudio y las restricciones de datos.

De manera narrativa, pueden distinguirse tres ejes que organizan el trabajo sobre OAI sin necesidad de recurrir a listados. Primero, el **objetivo predictivo** oscila entre una separación binaria (presencia de artrosis frente a ausencia) y una clasificación multiclase que cubre todos los grados KL (0–4), con variantes que fusionan categorías contiguas para mitigar la ambigüedad en los estadios leves. Cuando el interés está en reflejar la progresión clínica continua, la predicción se plantea como variable numérica, aproximando KL con una puntuación real en el intervalo $[0, 4]$. Segundo, el **régimen de entrenamiento** suele partir de pesos preentrenados en dominios generales (p. ej., ImageNet) y aplicar *fine-tuning* selectivo, práctica que acostumbra a superar a los modelos entrenados desde cero en imagen médica por la limitada disponibilidad de datos etiquetados. Tercero, la **función de pérdida** deja de ser neutral respecto a la distancia entre clases: además de la entropía cruzada canónica en escenarios categóricos, se emplean pérdidas ordinales o regresivas (MSE/MAE) que penalizan más los errores cuanto mayor es el salto entre grados, alineando el aprendizaje con la naturaleza escalonada de KL. A estos pilares se suman estrategias de apoyo—*data augmentation* realista, ponderación por clase ante desbalance, *ensembling*—y, cada vez con mayor peso, la interpretabilidad con *Grad-CAM* para verificar atención en regiones anatómicas plausibles.

En el marco de este Trabajo de Fin de Grado, se delimita el problema a la **clasificación del grado KL** empleando recortes de rodilla ya localizados y centrados como los que proporcionan las versiones procesadas difundidas en Mendeley y Kaggle. Se excluye deliberadamente la detección de la articulación y se prioriza la comparabilidad con la literatura mediante particiones predefinidas, protocolos de entrenamiento unificados

y métricas complementarias (accuracy, F1 macro en multiclase, AUC en binaria y MAE cuando la formulación adopta una escala continua). Para reforzar la lectura clínica, se contemplan mapas *Grad-CAM* sobre ejemplos representativos, con especial atención a los casos limítrofes entre KL 1 y KL 2, donde la discrepancia interobservador es mayor.

La bibliografía reciente ilustra bien estas decisiones de diseño. **Chen et al. (2019)** [4] proponen un sistema completo con detección (YOLOv2) y, en lo que aquí resulta más relevante, clasificación de la severidad con CNN preentrenadas (VGG, ResNet, InceptionV3, DenseNet). Su contribución central es una *adjustable ordinal loss* que incrementa la penalización con la distancia entre etiquetas, superando a la entropía cruzada y alcanzando un 70.4 % de *accuracy* con VGG-19 como mejor configuración. **Rafique et al. (2024)** [rafique2024knee] comparan VGG-16/19, ResNet-50/101 y EfficientNetB7 tanto en multiclase como en binaria por pares, mostrando la dificultad sistemática en KL1 y reportando, en el escenario extremo 0 vs. 4, una precisión del 99.13 % con EfficientNetB7; además, integran *Grad-CAM* para alinear las regiones activadas con zonas anatómicas de interés clínico. **Nabil et al. (2024)** [nabil2024automatic] optan por reetiquetar KL 0/1/2 como “sano” para estabilizar la frontera de decisión y plantean una clasificación en tres niveles (sano, moderado, severo) donde EfficientNetB7 se impone con un 93.90 % de *accuracy*, apoyado en un preprocesado cuidadoso y aumentos extensivos. Por último, **Fei et al. (2024)** [fei2024diagnosing] formulan explícitamente la tarea como **regresión continua**, evaluando VGG16, ResNet34, DenseNet169 y EfficientNetV2 (versión pequeña) sobre 8 260 imágenes de OAI; EfficientNetV2 destaca con un 71 % de *accuracy*, AUC 0.83 y MAE 0.42, evidenciando que una escala numérica capta con mayor finura la progresión y favorece aplicaciones de seguimiento longitudinal.

La Tabla 3.5 resume cuantitativamente estos trabajos, manteniendo la notación de clases y los escenarios de comparación tal y como se reportan en los artículos originales. Esta visión conjunta permite apreciar de un vistazo cómo la incorporación de la ordinalidad—ya sea mediante pérdidas específicas o mediante una formulación regresiva—tiende a mejorar la coherencia clínica, y cómo los *backbones* preentrenados dominan con claridad cuando el tamaño del conjunto no permite entrenamientos *from scratch* robustos.

Tabla 3.5: Comparativa de tareas y resultados en el dataset OAI

Estudio	KL 0–4	KL 0*-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
Chen et al. (2019)	70.4 %	–	–	–	–	–
Rafique et al. (2024)	58 %	–	78.11 %	82.33 %	91.53 %	99.13 %
Nabil et al. (2024)	–	94.09 %	–	–	–	–
Fei et al. (2024)	71 %	–	–	–	–	–

* 0 agrupa las clases KL 0, 1 y 2 como “sano”, frente a los grados 3 y 4 (“avanzado”).

En continuidad con la Tabla 3.5, la Fig. 3.4 resume el desempeño del mejor modelo en la clasificación KL 0–4. Con una *accuracy* global en torno al 71 %, los errores se producen casi siempre entre clases contiguas; destaca la frontera KL1-KL2 como la más conflictiva, mientras que los extremos (KL0 y KL4) muestran mayor separabilidad y apenas aparecen errores de largo alcance.




Figura 3.4: Matriz de confusión agregada en la clasificación multiclase KL 0–4 con el mejor modelo de Fei et al. (2024)[fei2024diagnosing]. Predominan los aciertos en la diagonal y las confusiones entre clases vecinas, especialmente KL1-KL2.

Este patrón refuerza el uso de formulaciones que internalizan la distancia entre clases (pérdidas ordinales o regresión) y aconseja complementar la métrica global con análisis por clase y verificaciones cualitativas (p. ej., mapas Grad-CAM) en los casos limítrofes.

En síntesis, la evidencia acumulada apunta a una tendencia clara: los modelos que internalizan la **estructura ordinal** del problema y se entrenan mediante **transferencia** con ajustes cuidadosos logran resultados más consistentes y clínicamente plausibles. Esta lectura guía el diseño experimental del presente trabajo, donde se comparan formulaciones categóricas y continuas sobre OAI, se acompaña cada resultado de un análisis cualitativo con *Grad-CAM* y se prioriza la reproducibilidad mediante particiones oficiales y protocolos unificados.

3.5 Conclusiones

Este capítulo ha asentado la base empírica y metodológica del proyecto. Por un lado, el *dataset* OAI proporciona el terreno de prueba adecuado para estudiar la clasificación de artrosis con anotaciones KL, a la vez que expone dos desafíos que condicionan toda la cadena experimental: el **desbalance de clases**, especialmente acusado en los grados severos, y la **subjetividad** de las etiquetas en estadios leves. Por otro, el conjunto veterinario de radiografías felinas introduce un cambio de dominio real con el que evaluar **generalización** y **transferencia**, aspectos cruciales si se pretende que los modelos trasciendan el laboratorio y se aproximen a escenarios clínicos diversos.

El repaso de tareas comunes sobre OAI muestra que la precisión global no basta para juzgar la utilidad clínica: es necesario complementar con métricas por clase, analizar los patrones de error (matrices de confusión) y, cuando la formulación lo permite, cuantificar el **error absoluto medio** para valorar la distancia entre la predicción y el grado real. El recurso a pérdidas ordinales o a la regresión continua emerge como una respuesta coherente a la escala KL, mientras que la **interpretabilidad**—materializada en mapas

Grad-CAM—sirve como control de plausibilidad sobre las regiones anatómicas usadas por el modelo.

Con estas ideas, los capítulos siguientes desarrollan un **diseño experimental** alineado con la literatura: comparación de *backbones* (CNN y Transformers) bajo formulaciones multiclase y continuas en OAI; evaluación con un conjunto estable de métricas y énfasis en la calibración; y validación externa en el dominio felino bajo tres regímenes (inferencia directa, entrenamiento específico y *fine-tuning* desde OAI). El objetivo es doble: medir el rendimiento de forma honesta y, al mismo tiempo, respaldar cada cifra con evidencias cualitativas y decisiones metodológicas que favorezcan su interpretación clínica.

CAPÍTULO 4

Redes Convolucionales

Este capítulo estudia el papel de las redes convolucionales (CNN) en la clasificación automática del grado *Kellgren–Lawrence* (KL) a partir de radiografías de rodilla. El objetivo es doble: por un lado, cuantificar cuánto aporta el aumento de complejidad arquitectónica y las técnicas modernas de regularización; por otro, determinar el beneficio neto del *transfer learning* frente a modelos entrenados desde cero en un escenario biomédico realista como OAI. El diseño experimental se ha construido para ser comparable con trabajos recientes y, a la vez, suficientemente transparente como para permitir su reproducción y auditoría.

La contribución específica de este capítulo no es únicamente presentar resultados agregados, sino ofrecer una lectura *explicable* del rendimiento: se registran métricas globales y por clase, se analizan los patrones de error en las fronteras más conflictivas (especialmente KL1-KL2) y se acompaña la discusión de representaciones visuales que facilitan el diagnóstico metodológico. Esta aproximación busca ir más allá de la *accuracy* y complementar la interpretación con medidas sensibles a la distancia ordinal y a la calibración de las probabilidades, aspectos clave en aplicaciones clínicas.

Para facilitar **la navegación**, el capítulo sigue un recorrido incremental: comienza con una motivación y encaje metodológico (Sección 4.1), continúa con la descripción de las arquitecturas evaluadas y los criterios de entrenamiento, y **culmina con** una batería de experimentos que cubren tanto la formulación multiclase 0–4 como variantes binarias y continuas. A lo largo del texto se proponen piezas visuales que ayudan a sintetizar información heterogénea: desde mapas de confusión enriquecidos con distancia ordinal, hasta curvas de aprendizaje y paneles de interpretabilidad.

4.1 Introducción

El propósito de esta introducción es situar con precisión el alcance del estudio y las preguntas que guía. Nos centramos en radiografías ya recortadas y centradas en la articulación, tal y como aparecen en las versiones procesadas disponibles públicamente. Esta decisión excluye deliberadamente la fase de detección para maximizar la comparabilidad con la literatura y aislar el efecto de la arquitectura de clasificación. El hilo conductor es evaluar, de forma controlada, cómo evoluciona el rendimiento al pasar de redes mínimas entrenadas desde cero a *backbones* preentrenados con *fine-tuning*, y cómo cambia la interpretación de ese rendimiento cuando la tarea se formula como multiclase, binaria o continua.

El contexto previo sugiere que la dificultad no es uniforme en toda la escala KL: los extremos son más separables, mientras que las fronteras entre grados contiguos concentran

la ambigüedad. Por ello, además de reportar métricas globales, se analizarán las matrices de confusión con énfasis en la estructura *ordinal* de los errores. Para que esta lectura sea informativa, la evaluación se acompaña de dos elementos complementarios. En primer lugar, *curvas de aprendizaje* que relacionan tamaño efectivo de datos y rendimiento, útiles para estimar si una arquitectura está limitada por datos o por capacidad. En segundo lugar, *mapas Grad-CAM* sobre casos representativos —correctos y fallidos— que permitan verificar la plausibilidad anatómica de la atención del modelo en las transiciones más problemáticas.

La comparación entre modelos se realizará bajo un protocolo idéntico de entrenamiento y validación. Para evitar sesgos de selección, el mejor punto de cada red se fija por desempeño en validación con *early stopping* y se reporta en *test* sin ajustes adicionales. Cuando la formulación sea continua, además de MAE se presentarán distribuciones de error absoluto por clase, lo que ayuda a identificar si el modelo subestima o sobrestima sistemáticamente ciertos grados. Con la finalidad de comunicar con claridad las diferencias entre arquitecturas, se propone un *panel comparativo* único que reúna, para cada red, las métricas principales, el coste computacional y un ejemplo de mapa de activación; esta pieza funciona como una “tarjeta de modelo” visual que agiliza la lectura transversal del capítulo.

Finalmente, para reforzar la utilidad aplicada del análisis, se incorporará una lectura de calibración y umbrales que muestre cómo varían sensibilidad y especificidad al ajustar la decisión entre categorías reagrupadas (p. ej., “sano” 0/1/2 frente a “avanzado” 3/4). Este apartado conecta con escenarios clínicos donde se prioriza el control del falso negativo y justifica el empleo de pérdidas que internalizan la distancia entre clases o formulaciones regresivas. Con este marco, el resto del capítulo desarrolla la comparación empírica entre arquitecturas y tareas, cuidando que cada cifra vaya acompañada de la visualización adecuada para su interpretación.

4.2 Modelos

El conjunto de modelos evaluados se ha seleccionado para cubrir un gradiente claro de complejidad y sesgo inductivo: desde arquitecturas mínimas construidas desde cero hasta *backbones* preentrenados en grandes corpus naturales. Este abanico permite aislar cuánto aporta la capacidad representacional y cuánto aporta el conocimiento previo reutilizado mediante *fine-tuning*. En todos los casos, las radiografías originales en escala de grises se han estandarizado geométricamente (recortes centrados en la articulación y 224×224 píxeles). Los modelos entrenados desde cero consumen una sola canalidad y aprenden filtros específicos del dominio, mientras que los preentrenados reciben tres canales obtenidos por replicación de la imagen para respetar **las estadísticas** de entrada de ImageNet y aprovechar sus pesos iniciales.

A continuación se describen, por separado, las tres CNN diseñadas específicamente para el problema. Todas comparten una cabeza de predicción adaptable: en configuración multiclase producen una distribución sobre KL 0–4 mediante activación *softmax*; en la versión continua emiten un escalar $\hat{y} \in [0, 4]$ optimizado con pérdidas tipo MAE/MSE. Esta simetría permite comparar con justicia el efecto de la arquitectura.

La *línea base* explora el mínimo necesario para discriminar patrones gruesos (bordes, texturas globales) y establece un suelo metodológico sobre el que medir cualquier ganancia posterior. Consta de un apilado reducido de capas convolucionales con *ReLU* y operaciones de *pooling* agresivas que aceleran la reducción espacial y limitan el número de parámetros, facilitando el entrenamiento estable con datos limitados.




Figura 4.1: Esquema *AlexNet-style* de la CNN simple (línea base)

La *CNN intermedia* incrementa la profundidad y el número de filtros para capturar combinaciones jerárquicas de rasgos anatómicos (p. ej., contornos de la interlínea articular y texturas trabeculares), manteniendo un coste computacional moderado. Esta configuración resulta apropiada en escenarios con recursos limitados en los que se busca un equilibrio entre capacidad y eficiencia.




Figura 4.2: Esquema *AlexNet-style* de la CNN intermedia

La *CNN profunda* añade bloques con normalización por lotes y *dropout*, una cabeza densa regularizada y una ruta de reducción espacial más lenta. El objetivo es aumentar la expresividad sin sacrificar generalización, algo especialmente relevante cuando los grados de severidad se diferencian por señales sutiles como el estrechamiento del espacio articular u osteofitos marginales.




Figura 4.3: Arquitectura CNN_Profunda implementada en Keras: tres bloques Conv-BN-Conv-BN-Pool-Dropout y cabeza densa con BN y Dropout.

El segundo grupo incorpora aprendizaje por transferencia con **EfficientNetB0** y **ResNet152**. Ambos *backbones* representan enfoques complementarios: EfficientNet equilibra profundidad, ancho y resolución mediante escalado compuesto, lo que se traduce en una relación rendimiento-eficiencia favorable; ResNet aporta estabilidad de optimización gracias a las conexiones residuales y sirve como estándar de comparación ampliamente aceptado. En ambos casos se ha utilizado una cabeza ligera adaptada a la tarea, conservando el tronco convolucional como extractor de características. Además, se han explorado dos regímenes de ajuste: un *congelado parcial* que actualiza únicamente la cabeza (útil como diagnóstico rápido y para reducir el riesgo de sobreajuste en fases iniciales) y un *ajuste fino completo* con tasas de aprendizaje diferenciadas entre capas, que permite resculpir las representaciones intermedias hacia las señales radiográficas específicas de KL. Esta doble vía no solo incrementa la probabilidad de alcanzar el máximo rendimiento, sino que también facilita entender el papel real del preentrenamiento frente a la adaptación específica. La Fig. ?? recoge los diagramas de adaptación estructural de ambos modelos.

4.3 Experimentos

En esta sección presentamos la evaluación empírica de cinco arquitecturas de *deep learning* sobre OAI (Osteoarthritis Initiative) bajo cuatro formulaciones: (i) clasificación multiclase (KL 0–4), (ii) clasificación ternaria (fusión 0-3-4), (iii) binaria por pares frente a la clase 0 (0 vs 1/2/3/4) y (iv) regresión continua al rango $[0, 4]$. Nuestros objetivos son dos: (a) cuantificar la ganancia asociada a cada incremento de complejidad o a la transferencia de conocimiento, y (b) analizar dónde fallan los modelos y cómo se comportan respecto a decisiones clínicas de cribado (p.,ej., operar con alta sensibilidad para detectar KL 3/4), conectando las métricas con implicaciones prácticas.

Datos y protocolo. Trabajamos con las particiones oficiales train/val/test de OAI. Todas las radiografías se redimensionan a 224×224 px, se normalizan y se replica el canal en escala de grises a 3 canales (RGB). El entrenamiento ha sido con Adam; tasa de aprendizaje 10^{-3} (y 10^{-4} en backbones), *batch* 32, hasta 50 épocas con *early stopping* (paciencia 10) y *ReduceLROnPlateau* (factor 0.5 tras 5 épocas sin mejora en validación). Las métricas de selección son F1 macro para clasificación y MAE para regresión; reportamos además *accuracy*, matrices de confusión, fiabilidad (ECE) y análisis de umbrales para “sano vs. avanzado” (0/1/2 frente 3/4). El punto óptimo se fija por desempeño en validación y se evalúa una única vez en test.

Contexto de porcentajes y *baselines*. Es imprescindible relativizar las % debido al desbalance de clases. En la tabla 4.1 se recogen las *accuracies* obtenidos en caso de clasificar únicamente la clase mayoritaria

Tabla 4.1: Baselines ingenuos por tarea en test (prediciendo siempre la clase mayoritaria).

ID	Tarea	Acc. ingenua
T0	KL 0–4 (multiclase)	38,6 %
T1	0-3-4 (ternaria; $0^* = \{0, 1, 2\}$)	83,5 %
T2	0 vs 1	68,3 %
T3	0 vs 2	58,9 %
T4	0 vs 3	74,1 %
T5	0 vs 4	92,6 %

Implicación práctica. En pares muy desbalanceados (p. ej., 0 vs 4), una *accuracy* del 90 % no evidencia capacidad discriminativa.

Reporte de resultados del modelo simple. El *Simple CNN* entrenado desde cero ofrece mejoras modestas sobre los *baselines* ingenuos de la Tabla 4.1, con un comportamiento heterogéneo según la formulación. En multiclase (KL 0–4) la ganancia en *accuracy* es limitada y el F1 macro permanece bajo, lo que evidencia dificultades para separar grados contiguos. En cambio, en las tareas binarias frente a estadios avanzados (0 vs. 3/4) el modelo comienza a discriminar adecuadamente algunas imágenes, con una *precisión media* del 46 %. En regresión, el MAE medio se sitúa por debajo de un grado KL; no obstante, la discretización posterior aún no supera a la clasificación directa en 0–4. En conjunto, este modelo sirve como línea base para valorar la aportación de arquitecturas más profundas y/o preentrenadas. En las tareas de clasificación binaria, el modelo es capaz de distinguir la clase 0 frente a las clases 3 y 4, alcanzando una *precisión media* por clase del 65 % en 0 vs. 3 y del 89 % en 0 vs. 4.

Tabla 4.2: Resultados Simple CNN en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	42 %	85.11 %	68.19 %	62.41 %	80.88 %	97.18 %
	Clasif.	F1-score	30 %	80.35 %	55.29 %	54.41 %	77.98 %	97.02 %
OAI	Regr.	Accuracy	34.87 %	84.38 %	—	—	—	—
	Regr.	F1-score	34.65 %	78.16 %	—	—	—	—
	Regr.	MAE	0.897	0.291	—	—	—	—

Reporte de resultados de la CNN intermedia. Al incrementar ligeramente la capacidad del modelo se observan mejoras moderadas respecto a la *Simple CNN*. En multiclase (KL 0-4) la *accuracy* asciende al 46.23 % y el F1 macro al 39.71 % (+9.71 pp), lo que indica una mejor separación entre grados contiguos, aunque aún insuficiente. El modelo mejora de forma clara en 0 vs. 3, alcanzando un 73.69 % de precision media y marginalmente en 0 vs. 4 donde alcanza un 90 % de precision media por clase separando casi completamente las clases 0 y 4. En regresión, el MAE disminuye a 0.771 (frente a 0.897) y a 0.237 en 0-3-4 (frente a 0.291); tras discretizar, se obtiene Acc. 34.87 % (0-4) y 84.02 % (0-3-4). En síntesis, la mayor capacidad aporta beneficios sobre todo en pares con mayor separación semántica (0 vs. 3/4), pero no resuelve las ambigüedades entre grados adyacentes.

Reporte: CNN intermedia. Aumenta capacidad con ligeras mejoras.

Tabla 4.3: Resultados CNN mediana en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	46.23 %	85.35 %	68.19 %	65.37 %	84.10 %	97.46 %
	Clasif.	F1-score	39.39 %	80.35 %	55.29 %	62.84 %	82.16 %	97.35 %
OAI	Regr.	Accuracy	34.87 %	84.02 %	—	—	—	—
	Regr.	F1-score	34.65 %	82.71 %	—	—	—	—
	Regr.	MAE	0.771	0.237	—	—	—	—

Reporte de resultados de la CNN profunda. Con el aumento de capacidad, el modelo mejora de forma clara. En multiclase (KL 0-4) llega al 58.47 % de *accuracy* y separa mejor las clases, aunque aún falla en los grados bajos (0-2). En 0-3-4 también sube hasta 89.35 %. En binarias destacan 0 vs. 2 (74.26 %) y 0 vs. 3 (86.64 %); 0 vs. 1 apenas cambia y 0 vs. 4 es casi perfecto (99.72 %), fallando únicamente en 1 imagen. En regresión, el error medio baja (MAE 0.651 y 0.171 en 0-3-4), pero al convertir a etiquetas la *accuracy* (43.95 % y 84.34 %) sigue por debajo de la clasificación directa.

Reporte: CNN profunda. Capacidad sustancialmente mayor; cierra parte de la brecha con transferencia.

Tabla 4.4: Resultados CNN grande en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	58.47 %	89.35 %	68.40 %	74.26 %	86.64 %	99.72 %
	Clasif.	F1-score	52.03 %	88.50 %	55.78 %	72.51 %	86.14 %	99.72 %
OAI	Regr.	Accuracy	43.95 %	84.34 %	—	—	—	—
	Regr.	F1-score	46.22 %	77.17 %	—	—	—	—
	Regr.	MAE	0.651	0.171	—	—	—	—

Reporte de resultados de EfficientNetB0 (transfer learning). Con transferencia y un tamaño contenido, ofrece el mejor equilibrio entre coste y rendimiento. En multiclase (0-4) alcanza 68.64 % de *accuracy* y en 0-3-4 sube hasta 94.07 %; en binarias rinde muy fuerte en 0 vs. 2 (87.22 %) y 0 vs. 3 (97.70 %), y roza el techo en 0 vs. 4 (99.72 %), manteniendo 74.01 % en 0 vs. 1. En regresión, el error cae de forma notable (MAE 0.463 y 0.102) y, al discretizar, la *accuracy* (65.13 % y 93.83 %) queda muy cerca de la clasificación directa.

Reporte: EfficientNetB0 (transfer learning). Mejor compromiso rendimiento-coste; sobresale en tareas difíciles.

Tabla 4.5: Resultados EfficientNetB0 en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	68.64 %	94.07 %	74.01 %	87.22 %	97.70 %	99.72 %
	Clasif.	F1-score	64.82 %	93.84 %	71.78 %	87.77 %	97.67 %	99.72 %
OAI	Regr.	Accuracy	65.13 %	93.83 %	—	—	—	—
	Regr.	F1-score	65.84 %	93.67 %	—	—	—	—
	Regr.	MAE	0.463	0.102	—	—	—	—

Reporte de resultados de ResNet-152 (transfer learning). Con un *backbone* más profundo, ofrece un rendimiento muy alto: 67.07 % en 0-4 y 95.16 % en 0-3-4. En binarias destaca con 0 vs. 4 (100 %) y cifras muy altas en 0 vs. 3 (96.31 %) y 0 vs. 2 (86.67 %), mientras que 0 vs. 1 se mantiene más discreto (68.61 %). En regresión mejora menos que EfficientNet (MAE 0.515 y 0.342) y, tras discretizar, las *accuracies* (59.56 % y 82.93 %) quedan por debajo de las de clasificación.

Tabla 4.6: Resultados ResNet152 en clasificación y regresión

Dataset	Tarea	Métrica	Particiones					
			0-4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	67.07 %	95.16 %	68.61 %	86.67 %	96.31 %	100 %
		F1-score	67.19 %	94.89 %	65.26 %	86.55 %	96.26 %	100 %
OAI	Regr.	Accuracy	59.56 %	82.93 %				
		F1-score	61.40 %	79.17 %				
		MAE	0.515	0.342				

Resumen global. De la vista transversal (Tabla 4.7) se desprende que la *transferencia* supera con claridad a los modelos entrenados desde cero. **EfficientNetB0** ofrece el mejor rendimiento: lidera en 0-4 (68.64 %) y en MAE (0.463), y es el más sólido en 0 vs. 1/2/3, quedándose muy alto en 0 vs. 4 (99.72 %). **ResNet-152** marca el techo en 0-3-4 (95.16 %) y alcanza el 100 % en 0 vs. 4, aunque en regresión queda por detrás de EfficientNet. La **CNN profunda** reduce la brecha respecto a los modelos simples, sobre todo en 0 vs. 2/3, pero sigue por debajo de la transferencia; la **simple** y la **intermedia** muestran mejoras moderadas. De forma consistente, *0 vs. 1* es la tarea más difícil, mientras que *0 vs. 4* está prácticamente saturada.

Resumen global (summary). Vista transversal con los principales indicadores y lectura clave.

Tabla 4.7: Resumen por arquitectura en test: exactitud en KL 0-4 y 0-3-4, exactitud en pares binarios (frente a 0) y MAE en regresión.

Modelo	Acc 0-4	MAE	Acc 0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
CNN simple	42.00 %	0.897	85.35 %	68.19 %	65.37 %	80.88 %	97.18 %
CNN intermedia	46.85 %	0.771	85.35 %	68.19 %	62.41 %	84.10 %	97.46 %
CNN profunda	58.47 %	0.651	89.35 %	68.40 %	74.26 %	86.64 %	99.72 %
EfficientNetB0	68.64 %	0.463	94.07 %	74.01 %	87.22 %	97.70 %	99.72 %
ResNet-152	67.07 %	0.515	95.16 %	68.61 %	86.67 %	96.31 %	100.00 %

Análisis cualitativo vía matrices de confusión (T0: KL 0-4). Como complemento a los indicadores globales (Accuracy y F1 macro), en la Fig. 4.4 mostramos las matrices de confusión normalizadas por filas (%) en test para cada arquitectura. Estas visualizaciones permiten identificar patrones de error sistemáticos más allá de la métrica agregada: en todos los modelos se concentra la confusión entre grados contiguos (KL1↔KL2 y KL2↔KL3), mientras que los extremos (KL0 y KL4) presentan mayor fidelidad. A medida que aumenta la capacidad y/o se incorpora transferencia de aprendizaje, la masa de probabilidades se desplaza hacia la diagonal (menos dispersión fuera de ella), con diagonales más nítidas en EfficientNetB0 y ResNet-152. Este comportamiento es coherente con la mejora de F1 macro observada en las Tablas de resultados y con los porcentajes concretos de la Tabla ?? para EfficientNetB0 (p. ej., 82 % de aciertos en KL0 y 91 % en KL4, con errores residuales hacia clases vecinas). En términos prácticos, estos patrones justifican el análisis posterior de umbrales para cribado “sano vs. avanzado” (0/1/2 frente a 3/4), dado que la mayor parte de las equivocaciones se produce en fronteras semánticamente próximas.




Figura 4.4: Matrices de confusión normalizadas (%) en test para la tarea T0 (KL 0–4). Las filas están normalizadas (suman 100%). Se observa el patrón común de confusión entre grados contiguos ($KL1 \leftrightarrow KL2$, $KL2 \leftrightarrow KL3$) y una identificación más fiable de los extremos ($KL0$ y $KL4$), que mejora con la capacidad del modelo y con la transferencia.

4.4 Conclusiones

Los experimentos sobre OAI confirman tres mensajes centrales. Primero, la **transferencia de aprendizaje** marca la diferencia: las arquitecturas preentrenadas superan de forma consistente a los modelos entrenados desde cero en todas las formulaciones. En particular, *EfficientNetB0* ofrece el mejor equilibrio entre coste computacional y rendimiento, liderando la clasificación KL 0–4 y el error en regresión, mientras que *ResNet-152* alcanza el techo en la tarea 0-3-4 y en el caso extremo 0 vs. 4. Segundo, la **dificultad no es uniforme entre tareas**: 0 vs. 1 es sistemáticamente el caso más complejo, coherente con la cercanía semántica entre clases, mientras que 0 vs. 4 está prácticamente saturado para las arquitecturas profundas.

El análisis cualitativo de las matrices de confusión refuerza estas conclusiones: los errores se concentran en *fronteras adyacentes* ($KL1 \leftrightarrow KL2$, $KL2 \leftrightarrow KL3$), con mayor fidelidad en los extremos ($KL0$ y $KL4$). Al aumentar capacidad y/o incorporar transferencia, la masa se desplaza hacia la diagonal, reduciendo la dispersión fuera de ella. Este patrón sugiere que parte del techo actual viene determinado por la ambigüedad intrínseca de las clases contiguas más que por una falta de capacidad global del modelo.

Desde el punto de vista práctico, los resultados recomiendan **separar objetivos de desarrollo por caso de uso**: (i) para *cribado “sano vs. avanzado”* (0/1/2 frente 3/4) es suficiente un modelo con transferencia (p.ej., *EfficientNetB0*) operando a alta sensibilidad, con umbrales ajustados sobre validación; (ii) para *estratificación fina* 0–4, la ganancia viene de *backbones* más profundos y de pérdidas que respeten la ordinalidad; (iii) para *pares binarios*, el beneficio de la capacidad aumenta con la distancia semántica (mejoras claras en 0 vs. 2/3, marginales en 0 vs. 1). En todos los escenarios, la mera *accuracy* debe interpretarse con cautela debido al desbalance; métricas por clase (F1 macro) y análisis *precision-recall* son más informativos, especialmente en pares muy desbalanceados.

En cuanto a **calibración y toma de decisiones**, los modelos muestran fiabilidad mejorable. Antes de fijar umbrales clínicos debería incorporarse una etapa de calibración (p.ej., *temperature scaling* o isotónica) y validarse la estabilidad de los puntos de operación (sensibilidad/especificidad) para evitar sobreajuste a la partición de validación. Este paso es especialmente relevante si el despliegue pretende apoyar decisiones con coste asimétrico de error (falsos negativos en KL 3/4).

Las **limitaciones** de este estudio condicionan la interpretación de los resultados: (i) todo el desarrollo y la evaluación se realizan sobre OAI; es necesaria validación externa para estimar la generalización a otros centros y protocolos de adquisición; (ii) se emplea una única resolución de entrada y un preprocesado uniforme, sin explotar recortes anatómicos ni información multivista; (iii) el etiquetado KL presenta variabilidad interobservador, lo que afecta especialmente a las fronteras entre clases adyacentes —el caso más problemático es 0 vs. 1—, donde, pese a no ser de las clases más minoritarias, el modelo muestra escasa discriminación; y (iv) no se exploraron de forma sistemática estrategias de balanceo por clase (p.ej., reponderación) ni *schedulers* y técnicas de *data augmentation* más avanzadas.



Como **líneas futuras**, proponemos: (a) pérdidas ordinales y *cost-sensitive* (p.ej., CO-RAL/ordinal regression, focal reweighting) para alinear la función objetivo con la estructura KL; (b) preentrenamiento auto-supervisado específico en radiografías para mejorar la transferencia (*contrastive/self-distillation*); (c) integración de señales clínicas y segmentación/atención sobre regiones relevantes (espacio articular, osteofitos); (d) estimación explícita de incertidumbre (ensembles, MC-Dropout) combinada con derivación a experto en casos dudosos; y (e) validación externa y evaluación prospectiva con *calibration-in-the-large* y métricas de utilidad clínica (PPV/NPV a distintos *prevalences*).

En síntesis, la transferencia de aprendizaje es el factor más determinante para mejorar el rendimiento en OAI; la dificultad se concentra en las fronteras ordinales y exige métricas y pérdidas acordes; y la correcta calibración y selección de umbrales es clave para transformar el buen rendimiento agregado en decisiones clínicas útiles y seguras. EfficientNetB0 surge como *modelo por defecto* por su robustez y eficiencia, mientras que ResNet-152 ofrece el máximo cuando el objetivo es expresar el rendimiento en escenarios con mayor presupuesto computacional.

CAPÍTULO 5

Transformers

5.1 Introducción

Este capítulo estudia el uso de *Transformers* para la clasificación automática del grado de artrosis de rodilla en radiografías, manteniendo el mismo marco experimental del capítulo de CNN. El interés principal radica en su capacidad para modelar dependencias *globales* mediante mecanismos de atención, a la vez que preserva señales locales gracias al particionado en parches. A diferencia de las CNN, que se basan en convoluciones jerárquicas, los Transformers procesan la imagen como una secuencia de *tokens*, permitiendo que cada región “vea” al resto de la imagen desde las primeras capas.

En el contexto de la escala de Kellgren-Lawrence (KL), los errores suelen concentrarse en fronteras adyacentes ($KL1 \leftrightarrow KL2$, $KL2 \leftrightarrow KL3$). Aquí la atención global puede resultar ventajosa al integrar información contextual sobre la articulación completa, más allá de detalles locales. De igual modo, en escenarios de cribado simplificado (sano vs. avanzado, i.e. 0/1/2 frente a 3/4), se espera que la sensibilidad aumente gracias a la capacidad de los Transformers de capturar patrones estructurales a gran escala (p. ej., el estrechamiento articular o la morfología del fémur y la tibia en conjunto).

El objetivo es valorar, con un protocolo homogéneo, hasta dónde llega un Transformer “puro” sin componentes convolucionales cuando se optimiza sobre OAI, y qué diferencias emergen entre variantes de distinta escala (base vs. large).

5.2 Modelos

Se exploran dos arquitecturas de Vision Transformer con diferente capacidad y huella computacional:

ViT-Base/16 (`google/vit-base-patch16-224`). La imagen de entrada (224×224 píxeles) se divide en parches de 16×16 (196 parches). Cada parche se proyecta linealmente a un espacio latente de dimensión 768 y se forma una secuencia de tokens a la que se añade un *class token* y embeddings posicionales. La secuencia pasa por 12 bloques Transformer con auto-atención multi-cabeza (12 cabezas) y capas MLP residuales. La cabeza de salida es intercambiable: *softmax* para clasificación multiclase (KL 0–4) o regresión escalar $\hat{y} \in [0, 4]$. Para compatibilidad con pesos preentrenados en ImageNet, la entrada en escala de grises se replica a RGB y se normaliza con las estadísticas estándar.

ViT-Large/16 (`google/vit-large-patch16-224`). Aumenta significativamente la expresividad gracias a **24** bloques y **16** cabezas de atención, con un embedding de dimensión 1024 y aproximadamente 300 millones de parámetros. Mantiene el mismo esquema de

parches y *tokens*, pero su mayor capacidad permite capturar señales ordinales sutiles propias de KL, a costa de una huella computacional mucho mayor (VRAM y tiempo de entrenamiento). Para estabilizar su ajuste en conjuntos médicos moderados se emplearon técnicas como: (i) *layer-wise learning rate decay*, (ii) *stochastic depth*, (iii) *warmup* breve y (iv) regularización adicional con *dropout*.

Tabla 5.1: Especificaciones estructurales (224×224 , parche 16). Parámetros aproximados para referencia.

Modelo	Parches	Tokens	Bloques	Cabezas	Dim. embed	Parámetros
ViT-B/16	16×16	$196+1$	12	12	768	~ 86 M
ViT-L/16	16×16	$196+1$	24	16	1024	~ 300 M




Figura 5.1: Esquema genérico de ViT: particionado en parches 16×16 , proyección a *tokens*, embeddings posicionales y bloques Transformer con autoatención. La cabeza se ajusta a clasificación KL 0–4 o a regresión en $[0, 4]$.


5.3 Experimentos

Se siguen las mismas particiones oficiales *train/val/test* de OAI y el mismo *pipeline* que en CNN para asegurar comparabilidad: optimizador Adam, 1×10^{-4} , *batch* 32, hasta 50 épocas con *early stopping* (paciencia 10) y *ReduceLROnPlateau* (factor 0.5, paciencia 5). Aumentos: rotaciones leves, *flip* horizontal y ajustes de brillo/contraste. La selección de modelo se realiza por F1 macro (clasificación) y MAE (regresión) en validación; el punto óptimo se evalúa una única vez en test. Como lectura cualitativa, se generan mapas de atención por *attention rollout* y matrices de confusión normalizadas por fila.

Tabla 5.2: Resultados de ViT-B/16 (google/vit-base-patch16-224) en test.

Dataset	Tarea	Métrica	Particiones / Pares					
			0–4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	65.45 %	92.37 %	69.64 %	80.74 %	96.54 %	99.44 %
		F1-score	63.48 %	82.38 %	48.31 %	80.00 %	95.24 %	98.00 %
OAI	Regresión	Accuracy	68.70 %	91.71 %	–	–	–	–
		F1-score	64.70 %	90.20 %	–	–	–	–
		MAE	0.4617	0.0603	–	–	–	–

Lectura rápida. ViT-B/16 supera claramente a las CNN entrenadas desde cero y se acerca al rendimiento de los *backbones* con transferencia: fuerte en 0–4 (65.45 %) y 0-3-4 (92.37 %), muy sólido en 0 vs. 3/4, MAE competitivo en regresión, y la mayor dificultad en 0 vs. 1 (F1 48.31 %), coherente con la frontera más difusa.



(a) ViT-B/16 (google/vit-base-patch16-224)

Figura 5.2: Matriz de confusión normalizada (%) en test para la tarea T0 (KL 0–4) con ViT-B/16 (google/vit-base-patch16-224).

Tabla 5.3: Resultados de ViT-B/16 (google/vit-base-patch16-224) en test.

Dataset	Tarea	Métrica	Particiones / Pares					
			0–4	0-3-4	0 vs 1	0 vs 2	0 vs 3	0 vs 4
OAI	Clasif.	Accuracy	64.91 %	92.37 %	67.98 %	79.83 %	94.19 %	99.27 %
		F1-score	64.92 %	72.31 %	40.47 %	79.36 %	92.72 %	97.37 %
OAI	Regresión	Accuracy	70.60 %	93.10 %	–	–	–	–
		F1-score	68.60 %	89.90 %	–	–	–	–
		MAE	0.4609	0.0736	–	–	–	–

Tabla 5.4: Comparativa resumida en test: Transformers vs. mejores CNN (valores de CNN tomados del capítulo anterior). El resultado de ViT-L/16 en 0–4 corresponde a la formulación de regresión.

Modelo	Acc 0–4	Acc 0-3-4	MAE (0–4)
CNN profunda	58.47 %	89.35 %	0.651
EfficientNetB0	68.64 %	94.07 %	0.463
ResNet-152	67.07 %	95.16 %	0.515
ViT-B/16	65.45 %	92.37 %	0.4617
ViT-L/16	70 %*	93.10 %	0.4609

* El valor de ViT-L/16 en 0–4 corresponde a la formulación de regresión.

5.4 Conclusiones

Los Transformers “puros” resultan una alternativa competitiva para OAI. Tanto ViT-B/16 como ViT-L/16 ofrecen resultados comparables e incluso superiores a CNN profundas, especialmente en regresión. El **punto débil común** sigue siendo la distinción entre KL0 y KL1, donde las fronteras clínicas son difusas y el ruido de etiquetado impacta con fuerza. Aun así, los ViT destacan en pares de mayor severidad (0 vs. 3/4) y en regresión, donde logran un MAE cercano a 0.46, mejorando las CNN.

En términos prácticos, ViT-L/16 parece ser la mejor opción en precisión global, pero a un coste computacional elevado; ViT-B/16 ofrece un mejor balance entre coste y rendimiento.

En conjunto, los Transformers aportan una visión complementaria a la inductiva de las CNN. Su integración o hibridación abre una vía prometedora para mejorar la fiabilidad de sistemas de ayuda al diagnóstico en artrosis de rodilla.

CAPÍTULO 6

Fine-tuning para radiografías de gatos

6.1 Introducción

La aplicación directa de modelos entrenados sobre radiografías humanas al dominio veterinario plantea un caso de transferencia con *shift* anatómico, estadístico y de adquisición. En este capítulo se evalúa la viabilidad de adaptar modelos optimizados previamente en OAI (rodilla humana) a radiografías de rodilla de gatos, analizando su rendimiento y su capacidad de generalización ante un cambio de morfología ósea, texturas de tejidos y distribución de severidades. Nuestro objetivo no es únicamente reportar métricas agregadas, sino entender *cómo* y *por qué* fallan (o aciertan) los modelos cuando cruzan de especie.

Para ello, ampliamos el análisis clásico de *accuracy*/*F1* con tres piezas clave: (i) **matrices de confusión** normalizadas por clase, que muestran dónde se concentran los errores (especialmente en fronteras adyacentes $1 \leftrightarrow 2 \leftrightarrow 3$) y el efecto del desbalanceo; (ii) **formulación de regresión** sobre la escala $[0, 4]$ con dispersogramas predicción,vs,verdadero y *MAE*, que permiten evaluar si el modelo aprende una noción continua de severidad más allá del acierto exacto; y (iii) **mapas Grad-CAM**, que aportan interpretabilidad visual al revelar si, tras la transferencia o el *finetuning*, el foco del modelo recae en estructuras anatómicas plausibles (espacio articular tibiofemoral, osteofitos marginales, esclerosis subcondral) o en artefactos espurios.

Comparamos tres regímenes de evaluación: *directo* (uso de pesos ImageNet sin adaptación específica), *indirecto* (modelos ajustados en OAI aplicados en modo *zero-shot* a gatos) y *finetuning* (reentrenamiento de los mejores modelos conseguidos en secciones anteriores). Esta triangulación permite medir qué conocimiento visual se transfiere de forma robusta y qué parte requiere reanclaje al nuevo dominio. Dado el tamaño limitado del conjunto felino, todos los resultados se contextualizan frente a la línea base de clase mayoritaria y se reportan métricas por clase para mitigar interpretaciones optimistas debidas al desbalanceo.

6.2 Selección de tareas y análisis de sentido clínico

El conjunto felino disponible es reducido y presenta un reparto de clases sesgado hacia los grados bajos, lo que recomienda diseños de tarea que equilibren utilidad clínica y viabilidad estadística. En consecuencia, se analizan dos formulaciones complementarias: (1) **clasificación multiclase 0–4**, que preserva la granularidad de la escala y permite estu-

diar el patrón de confusiones entre grados contiguos; y (2) **clasificación binaria 01vs234**, donde la clase sin artrosis" (0 y 1) se enfrenta a artrosis establecida" (2, 3 y 4). Esta segunda tarea refleja un escenario de cribado pragmático: prioriza la *sensibilidad* para detectar casos moderados/avanzados a costa de aceptar cierta imprecisión en la distinción fina entre 0 y 1.

Para ambas tareas, todas las métricas se interpretan a la luz de la *baseline* de predicción mayoritaria, con especial atención al *recall* por clase y al *F1* macro (robusto al desbalanceo). En la formulación continua, las salidas se calibran en $[0, 4]$ y se cuantifica el *MAE*; cuando se requiere una métrica discreta, las predicciones continuas se redondean (clip + round) a la clase más cercana, lo que permite comparar directamente con 0–4 y estudiar coherencia ordinal.

Con el fin de garantizar una lectura clínica y metodológica alineada, las matrices de confusión se normalizan por filas (verdaderos) y muestran soporte por clase; los dispersogramas de regresión incluyen la línea identidad y resumen de errores (*MAE*); y las Grad-CAM se ilustran sobre tres arquetipos (sano/leve, moderado, avanzado), comparando el foco atencional entre *directo*, *indirecto* y *finetuning*. Este diseño permite valorar, de forma integrada, la transferencia inter-especie tanto en rendimiento como en explicabilidad.

6.3 Experimentos realizados

Se evalúan dos *backbones*: **EfficientNetB0** y **ViT Base (patch16, 224)** de Google. Para cada uno se prueban tres regímenes de entrenamiento: (i) *Directo* (entrenar desde los pesos preentrenados de serie sobre el conjunto felino), (ii) *Indirecto* (*zero-shot* o *frozen*: evaluar sin reentrenar sobre gatos usando el modelo entrenado en OAI) y (iii) *Finetuning* (ajuste fino del modelo previamente preentrenado sobre OAI usando las imágenes felinas). Se reserva aproximadamente un 35 % para validación estratificada (~30 imágenes) con el fin de retener representación de clases poco frecuentes (p. ej., KL4).

Todas las imágenes se redimensionan a 224×224 y se normalizan. Los modelos preentrenados reciben tres canales (replicación de la escala de grises) para respetar las estadísticas de entrada. Para Grad-CAM, se emplea la última capa de activación previa al clasificador: bloque final de *inverted residual* en EfficientNetB0 y el *token* [CLS] proyectado a mapas vía *attention rollout* o capas *patch* en ViT. Los mapas se reescalan a resolución de entrada y se superponen como *heatmap* con normalización por imagen.

Los principales resultados cuantitativos para la tarea multiclase (0–4) se recogen en la Tabla 6.3, mientras que las matrices de confusión asociadas a cada modelo y régimen de entrenamiento se ilustran en las Figuras 6.4 y ???. Asimismo, los resultados bajo formulación de regresión se presentan en la Tabla ??, lo que permite comparar métricas de clasificación tradicionales con errores de predicción continua (*MAE*). .

Tabla 6.1: Resultados de la Tarea 0–4 para ViT y EfficientNetB0 con distintos tipos de entrenamiento

Modelo	Métrica	Directo	Indirecto	Finetuning
ViT (Google)	Accuracy	47 %	29 %	50 %
	F1-score	44 %	27 %	51 %
EfficientNetB0	Accuracy	40 %	17 %	30 %
	F1-score	39 %	9 %	22 %

Tabla 6.2: REGRESSION - Resultados de la Tarea 0–4 para ViT y EfficientNetB0 con distintos tipos de entrenamiento

Modelo	Métrica	Directo	Indirecto	Finetuning
ViT (Google)	Accuracy	33 %	39 %	47 %
	F1-score	33 %	39 %	47 %
	MAE	0.831	0.842	0.669
EfficientNetB0	Accuracy	30 %	33 %	40 %
	F1-score	30 %	13 %	40 %
	MAE	1.011	0.935	0.747




Figura 6.1: Matrices de confusión para ViT en la Tarea 0–4 (Indirecto, Directo y Finetuning).




Figura 6.2: Matrices de confusión para EfficientNetB0 en la Tarea 0–4 (Indirecto, Directo y Finetuning).

La Tabla 6.3 confirma que ViT supera consistentemente a EfficientNetB0 en clasificación multiclase, especialmente tras *finetuning*. La Tabla ?? refuerza esta conclusión al mostrar un MAE inferior en ViT, lo que refleja mayor estabilidad en predicción ordinal. Por su parte, las Figuras 6.4 y ?? revelan que el *finetuning* concentra la masa de probabilidad en la diagonal, reduciendo confusiones en clases intermedias, mientras que en el escenario *indirecto* persisten errores significativos por *domain shift*.

Síntesis de resultados (Tarea 0–4). En la tarea multiclase, ViT destaca en todos los regímenes, alcanzando en *finetuning* un Acc de 50 % y F1 de 51 %. El enfoque *indirecto*, sin embargo, se desploma (ViT 29 %, EffB0 17 %), lo que pone de manifiesto la necesidad de

adaptación al nuevo dominio. Las matrices de confusión (Figuras 6.4 y ??) evidencian que ViT reduce errores a desviaciones locales de ± 1 grado, mientras que EfficientNetB0 mantiene un fuerte sesgo hacia las clases mayoritarias. Este sesgo se refleja en la discrepancia entre Acc y F1, siendo este último más fiable para datos desbalanceados.

Tabla 6.3: Resultados de la Tarea 01vs234 para ViT y EfficientNetB0 con distintos tipos de entrenamiento

Modelo	Métrica	Directo	Indirecto	Finetuning
ViT (Google)	Accuracy	67 %	37 %	80 %
	F1-score	68 %	20 %	79 %
EfficientNetB0	Accuracy	70 %	42 %	73 %
	F1-score	69 %	40 %	73 %




Figura 6.3: Matrices de confusión para ViT en la Tarea 0–4 (Indirecto, Directo y Finetuning).




Figura 6.4: Matrices de confusión para EfficientNetB0 en la Tarea 0–4 (Indirecto, Directo y Finetuning).

Síntesis de resultados (Tarea 01vs234). Los resultados de la tarea binaria se presentan en la Tabla ?? . Aquí se observa un patrón similar: el ViT con *finetuning* alcanza Acc/F1 de 80/79 %, superando al escenario *indirecto* (37/20 %). EfficientNetB0, por su parte, obtiene valores estables tanto en *directo* como en *finetuning* (70/69 % y 73/73 % respectivamente). Esta diferencia muestra que la separación binaria es más sencilla que la clasificación ordinal fina, favoreciendo métricas más elevadas y generalización más sólida, especialmente en ViT.

En la tarea binaria 01vs234 se observa un patrón similar pero con mejoras claras en los valores absolutos: el **finetuning** de ViT alcanza Acc/F1 de 80/79 %, lo que supone una diferencia notable respecto al escenario indirecto (37/20 %). EfficientNetB0, en cambio, logra un rendimiento estable en directo (70/69 %) y finetuning (73/73 %), pero sin una ventaja clara frente a ViT. Estos resultados reflejan que la separación *negativo vs. positivo* es más sencilla que la clasificación ordinal fina, pues las fronteras amplias (0/1 frente a 2/3/4) reducen la ambigüedad y favorecen métricas más altas. En términos prácticos, mientras que la clasificación 0–4 sigue limitada por confusiones en los grados intermedios, el cribado 01vs234 demuestra que los modelos —especialmente ViT con *finetuning*— son capaces de generalizar con mayor solidez y resultan más adecuados para aplicaciones clínicas de detección temprana.

6.4 Interpretabilidad mediante Grad-CAM

Además del análisis cuantitativo y de las matrices de confusión, se incorporaron visualizaciones Grad-CAM para valorar la interpretabilidad de los modelos y comprobar si, tras la adaptación, las redes prestan atención a regiones anatómicamente plausibles.




Figura 6.5: Visualizaciones Grad-CAM para ViT en tres regímenes de entrenamiento.




Figura 6.6: Visualizaciones Grad-CAM para EfficientNetB0 en tres regímenes de entrenamiento.

En las Figuras 6.5 y 6.6 se observan diferencias moderadas entre modelos y regímenes. En el caso de **ViT**, el escenario *indirecto* muestra un foco principal en la rodilla, aunque con cierta dispersión; en el *directo*, las activaciones se vuelven más difusas y se concentran

en zonas periféricas de la imagen; y en el *finetuning*, el patrón se estabiliza de nuevo hacia el centro de la articulación, con algo de dispersión residual.

En **EfficientNetB0**, el escenario *indirecto* resalta de forma clara el estrechamiento del espacio articular, lo que resulta clínicamente razonable. En el *directo*, sin embargo, las activaciones se desplazan hacia zonas superior e inferior de la rodilla, menos informativas. Con *finetuning*, el foco vuelve al estrechamiento, de manera similar al patrón observado en el escenario indirecto.

En conjunto, las visualizaciones indican que el **finetuning mejora la coherencia de los mapas de activación** en ambos modelos, aunque no elimina por completo la dispersión. ViT tiende a mostrar activaciones más distribuidas, mientras que EfficientNetB0 concentra mejor en la línea articular en ciertos casos. Las diferencias no son drásticas, pero ambos modelos convergen hacia regiones clínicamente interpretables cuando se aplica un ajuste fino al dominio felino, lo que respalda la utilidad del *finetuning* más allá de las métricas cuantitativas.

6.5 Conclusiones

Los experimentos con radiografías felinas permiten extraer varias conclusiones relevantes desde el punto de vista metodológico y práctico. En primer lugar, se confirma que el **cambio de dominio inter-especie** constituye un reto importante: los modelos entrenados únicamente en rodillas humanas (*indirecto*) sufren un fuerte deterioro de rendimiento (ViT $\sim 29\%$, EffB0 $\sim 17\%$ en exactitud), con confusiones muy marcadas hacia la clase mayoritaria. Esto muestra que, aunque las representaciones genéricas (bordes, texturas) se transfieren parcialmente, la diferencia anatómica entre rodillas humanas y felinas requiere una adaptación explícita.

El entrenamiento *directo* en gatos ofrece una mejora respecto al escenario indirecto, pero sigue siendo limitado por el reducido tamaño del conjunto y el desbalanceo de clases. En este contexto, ViT logra resultados algo superiores a EfficientNetB0, lo que sugiere que su atención global le permite aprovechar mejor la información disponible, aunque con cierto grado de dispersión en sus predicciones.

El **finetuning** aparece como la estrategia más consistente. Adaptar modelos previamente entrenados en OAI proporciona ganancias claras: ViT alcanza alrededor del 50 % en la clasificación 0–4 y un 80 % en la tarea 01vs234, con un F1 equilibrado que refleja un mejor tratamiento del desbalanceo. EfficientNetB0 también mejora tras el ajuste fino, aunque de forma más modesta, confirmando que los Transformers se benefician más del reentrenamiento en escenarios con pocos datos y morfologías diferentes.

El análisis de las **matrices de confusión** revela patrones comparables a los observados en humanos: errores concentrados en las fronteras contiguas ($1 \leftrightarrow 2$, $2 \leftrightarrow 3$) y mayor fidelidad en los extremos (0 y 4). Con *finetuning*, ViT concentra más la masa en la diagonal, reduciendo las confusiones lejanas y reflejando un aprendizaje parcial de la ordinalidad. EfficientNetB0 mantiene un sesgo hacia clases frecuentes, lo que explica la brecha entre exactitud y F1.

La formulación **binaria 01vs234** ofrece una lectura más positiva. Al agrupar grados intermedios y avanzados, se reducen las ambigüedades locales y los modelos alcanzan métricas más altas. ViT con *finetuning* logra un 80 % de exactitud y 79 % de F1, un resultado competitivo para un escenario de cribado. EfficientNetB0 alcanza valores algo menores pero estables. Esto sugiere que, mientras la clasificación ordinal completa sigue siendo compleja, la separación entre “sano/leve” y “moderado/avanzado” es factible y clínicamente más útil.

Los experimentos de **regresión** complementan este análisis: el ViT ajustado reduce el MAE y refleja una noción continua de la severidad, con errores mayoritariamente de ± 1 grado. Este comportamiento puede ser valioso en aplicaciones donde se busque no solo clasificar, sino también monitorizar la progresión de la artrosis.

En cuanto a **interpretabilidad**, los Grad-CAM muestran que el ajuste fino ayuda a reorientar la atención de los modelos hacia regiones relevantes de la articulación. En ViT, las activaciones en *finetuning* se concentran en la zona central de la rodilla, aunque con cierta dispersión. En EfficientNetB0, tanto el escenario indirecto como el ajustado resaltan de manera consistente el estrechamiento del espacio articular, una región clínica clave, aunque en el entrenamiento directo aparecen activaciones menos informativas. Las diferencias entre arquitecturas no son drásticas, pero ambas coinciden en que el *finetuning* mejora la coherencia de los mapas y aumenta la plausibilidad clínica de las decisiones del modelo.

En conjunto, los experimentos en gatos permiten sintetizar tres conclusiones principales: (i) la transferencia *zero-shot* desde humanos no es suficiente y debe completarse con reentrenamiento específico; (ii) ViT muestra una adaptación más eficaz que EfficientNetB0 en escenarios pequeños y con morfología distinta, aunque ambos se benefician del *finetuning*; y (iii) la formulación binaria 01vs234 es la más prometedora para aplicaciones clínicas, al combinar mayor precisión con utilidad práctica.



CAPÍTULO 7

Conclusiones

7.1 Resumen del trabajo realizado

7.2 Objetivos alcanzados

7.3 Trabajo futuro

Bibliografía

- [1] Amazon Web Services. *Model Fit: Underfitting vs. Overfitting*. <https://docs.aws.amazon.com/machine-learning/latest/dg/model-fit-underfitting-vs-overfitting.html>. Consultado el 9 de abril de 2025. 2023.
- [2] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [3] Hila Chefer, Shir Gur y Lior Wolf. "Transformer Interpretability Beyond Attention Visualization". En: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2021, págs. 782-791. DOI: [10.1109/CVPR46437.2021.00083](https://doi.org/10.1109/CVPR46437.2021.00083).
- [4] Pingjun Chen et al. "Fully automatic knee osteoarthritis severity grading using deep neural networks with a novel ordinal loss". En: *Computerized Medical Imaging and Graphics* 75 (jul. de 2019), págs. 84-92. DOI: [10.1016/j.compmedimag.2019.06.002](https://doi.org/10.1016/j.compmedimag.2019.06.002). URL: <https://doi.org/10.1016/j.compmedimag.2019.06.002>.
- [5] Alexey Dosovitskiy et al. "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale". En: *arXiv* (2020). arXiv: [2010.11929 \[cs.CV\]](https://arxiv.org/abs/2010.11929).
- [6] Alexey Dosovitskiy et al. "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale". En: *International Conference on Learning Representations (ICLR)*. 2021. URL: <https://openreview.net/forum?id=YicbFdNTTy>.
- [7] Ligdi González. *Sesgo y Varianza en Machine Learning*. AprendeIA. 9 de nov. de 2018. URL: <https://aprendeia.com/2018/11/09/bias-y-varianza-en-machine-learning/> (visitado 11-08-2025).
- [8] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [9] Kaiming He et al. "Deep Residual Learning for Image Recognition". En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, págs. 770-778.
- [10] Alex Krizhevsky, Ilya Sutskever y Geoffrey E. Hinton. "ImageNet Classification with Deep Convolutional Neural Networks". En: *Advances in Neural Information Processing Systems (NIPS)*. Vol. 25. 2012, págs. 1097-1105.
- [11] Xiaoxuan Liu et al. "A comparison of deep learning performance against health-care professionals in detecting diseases from medical imaging: a systematic review and meta-analysis". En: *The Lancet Digital Health* 1.6 (2019), e271-e297. URL: [https://www.thelancet.com/journals/landig/article/PIIS2589-7500\(19\)30123-2/fulltext](https://www.thelancet.com/journals/landig/article/PIIS2589-7500(19)30123-2/fulltext).
- [12] Ze Liu et al. "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows". En: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, págs. 10012-10022. DOI: [10.1109/ICCV48922.2021.00986](https://doi.org/10.1109/ICCV48922.2021.00986).
- [13] Logongas. *Backpropagation y descenso del gradiente*. https://logongas.es/doku.php?id=clase:iabd:pia:2eval:tema07.backpropagation_descenso_gradiente. Consultado el 9 de abril de 2025. 2023.

- [14] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [15] National Institute of Arthritis and Musculoskeletal and Skin Diseases (NIAMS). *Osteoarthritis Initiative*. Web Page. Accessed: 2025-04-16. Available at: <https://www.niams.nih.gov/grants-funding/funded-research/osteoarthritis-initiative>. n.d. URL: <https://www.niams.nih.gov/grants-funding/funded-research/osteoarthritis-initiative>.
- [16] Frank Rosenblatt. "The Perceptron: a probabilistic model for information storage and organization in the brain". En: *Psychological Review* 65.6 (1958), págs. 386-408.
- [17] David E. Rumelhart, Geoffrey E. Hinton y Ronald J. Williams. "Learning representations by back-propagating errors". En: *Nature* 323 (1986), págs. 533-536.
- [18] Hugo Touvron et al. "Training data-efficient image transformers & distillation through attention". En: *Proceedings of the 38th International Conference on Machine Learning (ICML)*. 2021, págs. 10347-10357. URL: <https://proceedings.mlr.press/v139/touvron21a.html>.

APÉNDICE A

Configuración del sistema

APÉNDICE B

Otro apéndice
